



**אוניברסיטת בן-גוריון בנגב**

**הפקולטה למדעי ההנדסה**

**המחלקה להנדסת מכונות**

**דו"ח פרויקט**

# **פיתוח אלגוריתם ותכנ מערכת חישה לזיהוי התדרדרות שיווי משקל אצל קשישים**

שמות הסטודנטים : מאיה קופמן וגיל ששון

מספר פרויקט : 22-63

תאריך הגשה : 10.07.2022

שמות המנחים : פרופסור אמיר שפירא, פרופסור יצחק מלצר



**Ben-Gurion University of the Negev**



**Faculty of Engineering Sciences**

**Department of Mechanical Engineering**

**Project Report**

# **Sensing system design and algorithm development for balance decline detection and intervention in the elderly**

Students' names: Maya Kaufman, Gil Sasson

Project number: 22-63

Submission date: 10.07.2022

Advisors' names: Prof. Amir Shapiro, Prof. Itzik Melzer

## תקציר

ניידות גבוהה ממלאת תפקיד חשוב מאוד בקידום הזדקנות בריאה ופעילה ויש לה חשיבות רבה בסיוע עיכוב מוגבלויות ומניעת חולשה. ההזדקנות מאופיינת בשינויים תפקודיים במערכות התחושתיות, הנורולוגיות והשריר-שלד וכן בתפקוד קוגניטיבי, המשפיעים על הביצועים הפיזיים לרבות הליכה ואיזון יציבה. ליקויים בהליכה, בעיות שיווי משקל ושינויים קוגניטיביים בקרב מבוגרים הם גורם הסיכון העיקרי להפחתת רמות הפעילות הגופנית והגורמים העיקריים לנפילה. ישנו צורך בזיהוי נפילות אשר קשורות עם מוגבלות, שבריריות וליקויים קוגניטיביים שעלולים לגרום לפגיעה פיזית, טראומה רגשית, הימנעות מתנועתיות או הפחתת פעילות גופנית ואפילו מוות. דרך טובה להקטין את מספר הפציעות והנכויות הקשורות לנפילה עשויה להיות התאמת אמצעי ניטור לצורך זיהוי נפילה או התדרדרות במצב הקשישים, על מנת לנסות ולצמצם ואף למנוע נפילות בקרב מבוגרים בביתם.

מטרות הפרויקט העיקריות הינן פיתוח אלגוריתם המזהה התדרדרות שיווי המשקל אצל קשישים באמצעות מערכת חישה אשר תקלוט נתונים כגון זמן שהייה בחדר, שינויים במהירות ההליכה ובשונות ההליכה. ביצוע ניתוח ותרגום נתונים אלה להערכת מצב הנבדק תאפשר ליצור שיפור באורח חייהם של הקשישים עקב זיהוי שינויים בהליכה ובהתנהגותם האישית בחיי היומיום והפעלת תוכניות התערבות קליניות מתאימות ולבסוף אפשרות לזיהוי נפילות ואף כמעט נפילות וקריאה לעזרה במידה והמטופל לא יכול להגיע ללחצן המצוקה.

לאחר סקר ספרות מעמיק אודות הפרעות הליכה, חוסר שיווי משקל ונפילות אצל קשישים, מכשירים ואמצעי מדידה שונים ומחקרים קודמים הקשורים בפרויקט זה, נעשה זיהוי וניתוח של הסיכונים השונים העלולים להאריך ולפגוע בהתקדמות הפרויקט. לאחר ניתוח חלופות, הוחלט על מוצר מסוג מערכת חישה מבוססת חיישן LiDAR תלת-ממדי של חברת Leishen Intelligence System. זהו חיישן הבנוי מ-16 זוגות של מקריני לייזר ומקלטים במישורים שונים. ה-LiDAR מבצע סריקה פנורמית של  $360^\circ$  ומפיק ענן נקודות על ידי חישוב מרחקי המשטחים הנסרקים. יתרונות חיישן זה כוללים אי פגיעה בפרטיות המשתמש, יכולת לסווג אובייקטים תלת-ממדיים שונים תוך קבלת תוצאות מדויקות ועקביות. בנוסף, חיישן זה מוגדר בטוח לשימוש בעיניים חשופות (ללא מכשירים אופטיים מתקדמים).

במהלך הפרויקט צפו ועלו בעיות תכן כגון גילויי שווא ורעשים במדידות ובפרט במדידת המרחק האוקלידי, אשר נפתרו לאחר עבודה רבה וחישובים נוספים. לבסוף הוצג התכן של המערכת, הכולל את מערכת החישה שתהווה מעמד לחיישן כאשר חלקה העליון תופס את חיישן ה-LiDAR במקומו, וחלקה התחתון הינו כיסוי למפצל החשמל ולשנאי המתח הן של המחשב והן של ה-LiDAR. תכן המערכת כולל גם את האלגוריתם הראשוני למדידת חלק מהפרמטרים החשובים לניטור וזיהוי סיכונים אצל קשישים. האלגוריתם סיווג מדי פעם אובייקטים רחוקים, ובכדי להסיר חריגות אלה, נכתבה פונקציה מתאימה כתוספת לאלגוריתם.

על מנת לתקף את האלגוריתם שנכתב בוצעו מספר ניסויים. בניסוי הראשון נמדד המרחק האוקלידי אותו עובר הנבדק בהשוואה למרחק שנכתב שהוא מבצע על פי החיישן כדי לאמת את חישוב המרחק האוקלידי של האלגוריתם. בהמשך בוצעה סדרת ניסויים במעבדה של פרופסור איציק מלצר במחלקה לפיזיותרפיה, באמצעות מערכת ה-Vicon המתקדמת אשר נמצאת בה ומערכת ה-BaMPer שנבנתה בשיתוף פעולה קודם של המחלקה להנדסת מכונות והמחלקה לפיזיותרפיה בהנחייתם של פרופסור אמיר שפירא ופרופסור איציק מלצר. על מנת לוודא שניתן לזהות נפילות וכמעט נפילות על ידי מיקום מרכז המסה בציר האנכי כתלות בזמן. באמצעות השוואה בין המדידות שהתקבלו במערכת ה-VICON (state-of-the-art) לבין המדידות

שהתקבלו ב-LiDAR לשם תיקוף האלגוריתם. תוצאות ניסויים אלו הניבו מידע רב אודות האלגוריתם ויעילותו, בעיקר אימתו את קיום הקשר בין מרכז המסה בציר  $Z$  לנפילות וכמעט נפילות.

ההערכה הכלכלית למערכת זו מורכבת מעלויות חיישן ה-LiDAR, מחשב לניתוח הנתונים, מערכת החישה שהודפסה במעבדה של פרופסור אמיר שפירא ושכלול שעות העבודה על פרויקט זה. בנוסף לכך, במסגרת התוכנית הכלכלית של הפרויקט נערך סקר צרכנים בקרב קשישים בדיוור מוגן וילדיהם לגבי הצורך במוצר זה והסכום אותו הם מוכנים לשלם עבורו.

מחקרים הוכיחו כי התערבויות למניעת נפילות כחלק מהטיפול בקשישים בבית מגוריהם, עשויות להפחית את הסיכון לנפילה. לפיכך, פרויקט זה משמעותי ביותר, בעל חשיבות רבה לשיפור אורח חייהם של הקשישים וכחלק מהתפתחות הטכנולוגיה יש לשים דגש על פיתוח נושא זה.

## Abstract

High mobility plays a very important role in promoting healthy and active aging and is of great importance in helping to delay disabilities and prevent weakness. Aging is characterized by functional changes in the sensory, neurological and musculoskeletal systems as well as cognitive function, which affect physical performance including walking and posture balance. Walking impairments, balance problems and cognitive changes in adults are the main risk factor for physical activities and are the main causes of falls. There is a need to identify falls that are associated with disabilities, fragility and cognitive impairments that can result in physical injury, emotional trauma, avoidance of movement or reduced physical activity and even death. A good way to reduce the number of injuries and disabilities associated with falls may be to adjust monitoring measures to detect falls, almost falls and balance decline in the elderly. In that manner, we aim to reduce and even prevent falls among adults in their homes.

The main objectives of the project are to develop an algorithm that can point to balance decline through a sensing system that will generate data such as the time spent in the room, walking speed, distance traveled, number of almost falls, et cetera. Performing analysis and translating this data to assess the patient's condition. Achieving this could make it possible to improve the life expectancy of the elderly due to identifying changes in gait, performance decline and therefore implementing appropriate clinical intervention programs. And finally, the possibility of identifying near falls, falls and even call for help if the patient is unable to reach distress button.

After an in-depth literature review on gait disorders, imbalances and falls in the elderly, various instruments and measures and previous studies related to this project, an identification and analysis was made of the various risks that may prolong and impair project progress. After analyzing alternatives, it was decided that a 3D-based sensing system such as the Leishen Intelligent System's C16 LiDAR. The LiDAR is made of 16 pairs of laser projectors and receivers in different planes. The LiDAR performs a panoramic scan of 360 degrees at 20 Hertz and produces what is called a PointCloud which is the collection of locations in space of the various objects in the scanned area that has been projected by the lasers, by calculating the distances of the scanned surfaces and their respective azimuth and plane. The advantages of this type of sensor include non-invasion of user privacy, the ability to classify various 3D objects while obtaining relatively accurate and consistent results and in addition this sensor is considered safe for the naked eye (i.e., looking directly at the sensor's lasers with advanced optical devices is not).

During the project problems arose such as false detections and noises in the measurements which resulted in wrong Euclidean distance calculations which were solved after the addition and introduction of filters. Finally, the system's general design and algorithm were presented, which included the sensing system which includes LiDAR mount, electronics storage and a computer.

The system includes algorithm for measuring some of the important parameters for risk detection in the elderly, almost falls and falls. Another problem that rose is that the algorithm occasionally classified distant objects. In order to remove these anomalies, an appropriate function was written as an addition to the algorithm.

In order to validate the written algorithm, a number of experiments were performed. In the first experiment, the distance traveled by the subject is measured using the LiDAR's system and the aforementioned Euclidean distance function which was then compared with the actual distance that's been measured using a meter. Following the success of the first experiment, a series of additional experiments were performed in Prof. Itzik Meltzer's laboratory, located in The Department of Physiotherapy, using the advanced Vicon system and the BaMPer system which was built in previous collaborations between the Department of Mechanical Engineering and the Department of Physiotherapy under the supervision of Prof. Amir Shapira and Prof. Itzik Meltzer. These experiments were to ensure the hypothesis that falls and near-falls can be detected tracking the center of mass in the vertical axis as a function of time. In addition, to make a comparison between the measurements obtained by the VICON system (state-of-the-art) and the measurements obtained by the LiDAR system in order to validate the algorithm's functionality. The results of these experiments yielded a great deal of information about the algorithm such as the accuracy of the LiDAR system and the verification of said hypothesis i.e. the connection between the center of mass' location in the vertical axis and near falls and subsequently, falls.

Economic assessment were made for such system. The system's price was estimated by taking into account the LiDAR's price, the computer's price, the LiDAR's production cost, which was 3D printed in Prof. Amir Shapira's laboratory, the students' working hours value as well as the supervisors' and professional laboratory assistant hours. In addition, as part of the project's economic plan, a consumer survey was conducted among elderly people in sheltered housing and their children regarding the need for this product and the amount they are will be willing to pay for it.

Studies have shown that preventative interventions as a treatment for the elderly in residence may reduce the risk of falls. Therefore, this project and its further development is of great importance and potential.

## חוות דעת המנחים

פרופ' מלצר – פרויקט מצוין וחיוני הן מבחינת הצרכים עבור אוכלוסיית הקשישים שמספרם היחסי באוכלוסייה הולך וגדל וצפוי להיות 25-30% ב-2050 במדינות מערביות והן מבחינת האתגר ההנדסי.

הצלחה של פרויקטים מסוג זה תלויים בשלושה דברים (לעניות דעתי) :

1. יכולת לזהות ברמת דיוק גבוהה נפילות וכמעט נפילות עם מינימום טעויות ( false positive and true negative).

2. המערכת שומרת על פרטיות האדם.

3. תפיסת הקשישים למידת החשיבות של המערכת ורצונם לרכוש מערכת זו.

פרופ' שפירא – עבודה יפה מאוד, הנושא חדשני ויתרום רבות לשיפור מעקב שיווי המשקל של אנשים מבוגרים. הסטודנטים השתלטו על חומר בנושא עיבוד ענן נקודות במהירות, ואף פיתחו אלגוריתמיקה משלהם כדי לזהות נפילות. אני מאוד מרוצה מההתקדמות ומהתוצאות. הפרויקט ימשיך גם בשנה הבאה עפ"י המלצות הסטודנטים כדי להביא מוצר בשל יותר לשוק.



פרופ' איציק מלצר



פרופ' אמיר שפירא

## תוכן עניינים

1	מבוא	1
2	רקע	2
2.1	סקר ספרות	2.1
2.1.1	הדרדרות בשיווי משקל בקרב קשישים	2.1.1
2.1.2	הפרעות הליכה המאפיינות את הקשיש	2.1.2
2.1.3	נפילות	2.1.3
2.1.4	מחקרים קודמים	2.1.4
2.1.5	מכשירים ואמצעי מדידה שונים	2.1.5
2.2	ROBOT OPERATING SYSTEM	2.2
2.2.1	Rviz	2.2.1
2.3	LiDAR	2.3
2.3.1	LeiShen Intelligent System's 16-Line Mechanical LiDAR	2.3.1
2.4	בינה מלאכותית	2.4
2.4.1	ניתוח אשכולות	2.4.1
2.4.2	מכונת תמך וקטורי	2.4.2
2.4.3	מסנני חלקיקים	2.4.3
2.4.4	רשת עצבית מלאכותית	2.4.4
2.4.4.1	נוירון ומשקולות	2.4.4.1
2.4.4.2	Gradient Descent	2.4.4.2
2.4.4.3	Backpropagation	2.4.4.3
2.4.4.4	בעיית הגרדיאנט הנעלם (The Vanishing Gradient Problem)	2.4.4.4
2.4.4.5	רשת LSTM	2.4.4.5
2.5	VICON	2.5
2.5.1	מצלמות	2.5.1
2.5.2	מרקרים וחליפה	2.5.2
2.5.3	Vicon-Nexus	2.5.3
2.6	BAMPER-BALANCE MEASURE & PERTURBATION	2.6
2.6.1	ביצועי המערכת המכאנית	2.6.1
2.6.2	משתנים שיקבעו על ידי המפעיל	2.6.2
2.6.3	עיקרי המערכת המכאנית	2.6.3
2.6.4	מערכת הבקרה ותכנת ה-Balance Tutor	2.6.4
2.6.5	פרוטוקול	2.6.5
3	מפרט דרישות המערכת	3
3.1	דרישות כלליות	3.1
4	בעיות התכן ואלטרנטיבות לפתרון	4
4.1	גילויי שווא	4.1
4.2	"רעשים" במדידת המרחק האוקלידי	4.2
4.3	רזולוציית מכשיר המדידה	4.3
5	תכן רעיוני של המערכת	5
5.1	תכן למתקן מערכת החישה	5.1
6	תוספות לאלגוריתם הקיים	6



22	6.1	זמן שהייה בחדר
23	6.2	מרחק אוקלידי
21	6.3	אלגוריתם ראשוני לחישוב הפרמטרים
24	6.4	פונקציה לזיהוי והסרה של מדידות חריגות
27	6.4.1	שיטת טווח בין-רבעוני להסרת מדידות חריגות
28	6.4.2	שיטת ציון התקן להסרת מדידות חריגות
28	6.4.3	קוד הפונקציה להסרת מדידות חריגות
30	6.5	פלט נתונים למשתמש
30	7	<b>אימות עקרונות האלגוריתם</b>
30	7.1	אימות חישוב המרחק האוקלידי באמצעות האלגוריתם הראשוני
32	7.2	תיקוף האלגוריתם באמצעות ניסוי במערכות ה-VICON וה-BAMPER
32	7.2.1	מהלך הניסוי
33	7.2.2	תוצאות הניסוי
35	7.3	עריכת הניסוי במערכת ה-LiDAR
35	7.3.1	מהלך הניסוי
35	7.3.2	תוצאות הניסוי
38	7.4	השוואה בין תוצאות ה-LiDAR וה-VICON
41	7.4.1	מסקנות
42	8	<b>הערכה כלכלית</b>
43	8.1	סקר צרכנים
43	8.1.1	ענו בשם עצמם
44	8.1.2	ענו בשם בן משפחה
44	9	<b>סיכום</b>
45	9.1	תכנית להמשך הפרויקט
45	9.1.1	שימוש בבניה מלאכותית לזיהוי כמעט נפילות ונפילות
51	9.1.2	דוח מעקב חודשי
51	9.1.3	קשר עם מוקד חירום
51	9.1.4	ממשק משתמש גרפי

## רשימת איורים

מספור	תיאור	עמוד	מקור
2.1	מדידת המרחק של קרן הלייזר בטכנולוגיית LiDAR	6	Lidar [1]
2.2	תיאור מבנה הלייזר של חברת LeiShen Intelligent System C-16 LiDAR	7	Operation Instruction of C16 Series Multi-line Hybrid Solid-State Lidar [2]
2.3	העל-מישור, H3 מפריד בין שתי הקבוצות השונות עם גבול שוליים מקסימלי	8	Wikipedia, Support-Vector Machine [12]
2.4	תיאור רשת עצבית מלאכותית	9	Michael Nielsen, Neural Networks and Deep Learning [22]
2.5	קלט ופלט בנוירון פרספטרון	9	Michael Nielsen, Neural Networks and Deep Learning [22]
2.6	פונקציית הסיגמויד $\sigma$	10	Michael Nielsen, Neural Networks and Deep Learning [22]
2.7	קוד פייתון של האלגוריתם Gradient Descent	10	Wikipedia, Gradient Descent [39]
2.8	מיקום המרקרים על גבי הנבדק	12	-
2.9	צילום מקורי של מערכת ה-BaMPer הכוללת את הבמה והרתמה	14	-
4.1	מערכת הצירים ב-Rviz	17	ROS.org, Display Types, Axes [38]
5.1	סקירה כללית של המערכת המוצעת	19	-
5.2	עקרון תהליך פיתוח האלגוריתם	20	-
5.3	מודל חיישן הלייזר ומעמד הלייזר SOLIDWORK	20	
5.4	חיישן ה-LiDAR ומעמד ה-LiDAR המודפס	21	
6.1	אלגוריתם ראשוני לחישוב הפרמטרים	22	-
6.2	אלגוריתם לחישוב זמן השהייה בחדר	23	

	24	אלגוריתם לחישוב המרחק האוקלידי	6.3
-	25	מדידות פיקטיביות עבור מרחק כפונקציה של הזמן בהן ישנן מדידות חריגות עם מרחק אפס	6.4
-	25	גרף של המרחקים כתלות בזמן לפני הפעלת הפונקציה	6.5
-	26	גרף של המרחקים כתלות בזמן אחרי הפעלת הפונקציה	6.6
-	26	מדידות פיקטיביות עבור מרחק כפונקציה של הזמן בהן ישנן מדידות חריגות	6.7
Interquartile range, Wikipedia [41]	27	תרשים קופסה עם טווח בין-רבעוני ופונקציית צפיפות-הסתברות	6.8
-	28	הקריאה לפונקציית הסרת המדידות החריגות	6.9
-	29	קוד הפונקציה להסרת המדידות החריגות	6.10
-	29	אלגוריתם פעולת הפונקציה לזיהוי מדידות חריגות	6.11
	30	קוד להדפסת הנתונים	6.12
-	31	תוצאות הניסוי לאימות אלגוריתם חישוב המרחק האוקלידי	7.1
-	31	מדידת מרחק המסלול בניסוי לאימות האלגוריתם המחשב את המרחק האוקלידי	7.2
-	32	הגדרת נתונים במערכת ה-Balance Tutor	7.3
-	33	סכמת מערכת הניסוי	7.4
-	34	גרף מיקום תלות פריים	7.5
-	34	גרף מהירות תלות פריים	7.6
-	35	הנבדק על גבי הסימולציה בפריימים שונים של הניסוי	7.7

-	36	הפונקציה שמדפיסה את קובץ csv	7.8
-	36	צילום מקובץ txt של פרוטוקול הניסוי	7.9
-	37	מרכז האשכול על פי האלגוריתם	7.10
-	37	מהירות מרכז האשכול על פי האלגוריתם	7.11
-	38	זיהוי הנבדק שעומד על ה-BaMPer על ידי חיישן ה-LiDAR	7.12
-	38	מיקום מרכז המסה בציר האנכי כפונקציה של ה-Frame במערכת ה-Vicon	7.13
-	39	מהירות מרכז המסה בציר האנכי כפונקציה של ה-Frame במערכת ה-Vicon	7.14
-	39	מיקום מרכז המסה בציר האנכי כפונקציה של הזמן במערכת ה-Vicon	7.15
-	39	מהירות מרכז המסה בציר האנכי כפונקציה של הזמן במערכת ה-Vicon	7.16
-	40	מיקום מרכז האשכול בציר האנכי כפונקציה של הזמן במערכת ה-LiDAR	7.17
-	40	מהירות מרכז האשכול בציר האנכי כפונקציה של הזמן במערכת ה-LiDAR	7.18
	41	חלקי הגרפים השונים לפי הזמן בהם נראית התאמה בניסויים	7.19
-	42	צילום מסך מתוך סימולציית הניסוי	7.20
-	43	מצב סוציאקונומי לפי הכנסה חודשית של העונים בשם עצמם	8.1
-	44	מצב סוציאקונומי לפי הכנסה חודשית של העונים בשם בן משפחה	8.2
-	46	טבלת הנתונים כ- DataFrame ומקורם	9.1
-	46	הזמנים בהם התרחשה "כמעט נפילה"	9.2
-	47	חילוק הנתונים ל-train ו-test	9.3

-	47	נורמליזציה על ידי Robust Scaler	<b>9.4</b>
-	48	המרת הנתונים לפורמט של סדרת זמן	<b>9.5</b>
-	48	הגדרת מודל רשת ה-LSTM	<b>9.6</b>
-	48	אימון של המודל על הנתונים	<b>9.7</b>
-	49	עקומת הלמידה שהתקבלה מנתוני הניסויים	<b>9.8</b>
-	49	יצירת מודל החיזוי	<b>9.9</b>
-	50	המחשה גרפית של מודל החיזוי	<b>9.10</b>
-	50	דוגמא לוגית ליישום חיזוי נפילות באמצעות "כמעט נפילות"	<b>9.11</b>
-	-	גאנט הפרויקט	<b>10.1</b>
Pedestrian recognition using high-definition LIDAR [13]	-	תהליך זיהוי הולכי הרגל של Kidono	<b>12.1</b>
-	-	מידות החלק העליון	<b>12.2</b>
-	-	מידות החלק התחתון	<b>12.3</b>

## רשימת טבלאות

מספור	תיאור	עמוד
2.1	משמעות שמות המרקרים	12
4.1	חלופות עבור מכשיר המדידה	18
8.1	מוצרי מדף והערכה כלכלית	42
10.1	ניתוח סיכונים	-

## רשימת סימנים

סימן	תיאור	יחידות
$c$	מהירות האור	$\frac{m}{sec}$
$d$	מרחק	m
$d_{Euclidean}$	מרחק אוקלידי	m
$e_i$	ווקטור עצמי עם אינדקס i	-
$f$	ווקטור המאפיינים	היחידות משתנות ממאפיין למאפיין
$f_i$	מאפיין עם אינדקס i	היחידות משתנות ממאפיין למאפיין
$m$	ווקטור הממוצע מכל דגימה	m
$M$	טנזור מומנט ההתמד המנורמל	$m^2$
$n$	מספר מדידות	--
$p$	מספר הממדים של מרחב כלשהו	-
$s_k$	אובייקט עם אינדקס k	-
$t$	זמן	sec
$X_i$	בציר i קואורדינטה x	-
$X_{ik}$	הנקודות במרחב הקרטזי השייכות לאובייקט k	m
$Y_i$	בציר i קואורדינטה y	m
$\lambda$	ערך עצמי עם אינדקס i	אותן היחידות של המטריצה ממנה חושב
$\Sigma$	מטריצת השונות המשותפת	מהכפלת היחידות של שתי המשתנים
$\sigma$	פונקציה גזירה המדמה פונקציית מדרגה	-

## 1. מבוא

מגזר הבריאות הציבורי והפרטי יצטרך לפתח טכנולוגיות מתקדמות על מנת להתמודד עם האוכלוסייה המזדקנת ברחבי העולם. מצב זה רק יחמיר כאשר מספר האנשים מעל גיל 60 יגדל באופן דרמטי עד שנת 2050 [1]. בהקשר זה, שמירה על בטיחות הקשישים בבתייהם למשך זמן רב ככל האפשר, חייבת להיות בראש סדר העדיפויות [2]. עם זאת, טיפול ביתי עדיין דורש כמות עצומה של משאבים ועלויות (מטפלים ואחיות לביקור הקשישים בביתם), עם סיכונים בטיחות פוטנציאליים. בעוד שפעמים רבות הקשישים נמצאים בביתם לבד (כגון נפילות או יכולת זיהוי של ירידה בתפקוד, פגיעה מוטורית או קוגניטיבית). יכולת לניטור טיפול ביתי באמצעות טכנולוגיה הופך לפתרון פופולרי יותר ויותר, זאת על מנת להתגבר על הבעיות שהוזכרו לעיל עימן מתמודד מגזר הבריאות [2]. ישנו צורך בזיהוי נפילות, אשר קשורות עם מוגבלות, שבריריות וליקויים קוגניטיביים ואשר עלולות לגרום לפגיעה פיזית, טראומה רגשית, הימנעות מתנועתיות או הפחתת פעילות גופנית ואפילו מוות. מחקרים הוכיחו כי התערבויות למניעת נפילות כחלק מהטיפול בקשישים בבית מגוריהם, עשויות להפחית את הסיכון לנפילה [3] לכן דרך טובה להקטין את מספר הפציעות והנכויות הקשורות לנפילה עשויה להיות התאמת אמצעי ניטור לצורך זיהוי נפילה או התדרדרות במצב הקשישים, ואף ניבוי של ירידה תפקודית על מנת לנסות ולצמצם ואף למנוע נפילות בקרב קשישים בביתם. אף על פי כן, הפתרונות הקיימים עדיין מצביים אתגרים. פתרונות לבישים לרוב אינם אידיאליים כאשר מטפלים במטופלים מבוגרים, מכיוון שלעתים קרובות הקשישים אינם "אוהבים" אותם וצריכים לזכור ללבוש ולהטעין אותם. כאשר דנים בחיישנים פסיביים לחלוטין, קיימות שתי גישות אפשריות: ישנן מערכות פשוטות המשתמשות בחיישני תנועה ומערכות מתקדמות יותר המשתמשות במצלמות או מיקרופונים. לשתי שיטות אלה חסרונות שונים המעלים את הצורך בפתרון נוסף.

פרויקט זה, בהנחייתם של פרופסור אמיר שפירא מהמחלקה להנדסת מכונות ופרופסור יצחק מלצר מהמחלקה לפיזיותרפיה, נועד לנסות ולקדם את הפתרון האידיאלי באמצעות פיתוח אלגוריתם ותכן מערכת חישה באמצעות חיישן LiDAR 3D אשר מסוגל לזהות מכשולים וסביבות כעננים נקודתיים "אנונימיים" לחלוטין כך שפרטיות הקשיש אינה נפגעת. החיישן יבצע ניטור ארוך טווח ובדיקה קלינית תוך כדי שמירה על פרטיות מלאה של הצרכן, באופן כזה שיוכל לזהות את האדם, או במקרה הנוכחי הקשיש אשר נמצא בביתו הפרטי ולעקוב אחר יציבותו באופן בו תהיה אפשרות לזהות התדרדרות בשיווי המשקל ואף נפילה או "כמעט נפילה" של אותו קשיש. המטרה העליונה היא לאפשר זיהוי סיכונים מוקדם, באמצעות זיהוי והתרעה כאשר ישנה התדרדרות במצבם של הקשישים, או זיהוי שינויים בהליכה ובהתנהגותם האישית בחיי היומיום ואף זיהוי התרעה במצב של נפילה אמיתית, על מנת לנסות ליצור שיפור באורח חייהם של הקשישים בעזרת תוכניות התערבות קליניות מתאימות.



## 2. רקע

### 2.1. סקר ספרות

#### 2.1.1. הדרדרות בשיווי משקל בקרב קשישים

מנגנון בקרת שיווי המשקל מורכב מבקרה מרכזית במוח, בעיקר בתת ההכרה, באמצעות מעגלים עצביים מהגרעינים הבזליים, (קבוצה של גרעינים במוח, הממוקמים בעומק המוח הגדול, ומתחת לקליפת המוח): המוחון (cerebellum), התלמוס והקליפה המוחית (cortex cerebral). מעגלים אלו ניזונים ממשותב תחושת מחיישנים היקפיים בעור, בשרירים, בפרקים, וממסילות בחוט השדרה. כמו כן, נודעת חשיבות רבה למשותב מהחושנים הייחודיים: מערכת הראייה והמערכת הווסטיבולרית (אברון שיווי המשקל באוזן הפנימית). תנועות הצוואר והגירויים מהמערכת הווסטיבולרית אל המעגל התת-קליפתי בתלמוס. מהמעקב התחושת יוצאים מסרים המגיעים דרך מסילות מוטוריות בחוט השדרה אל השרירים, על מנת לשמור על איזון הגוף ביחס למרחב הסביבתי, הן במנוחה והן בתנועה. המערכת הווסטיבולרית נמצאת באוזן הפנימית ופועלת בשיתוף עם המערכת החושית (פרפריוצפטיבית) ומערכת הראייה. כדי להשיג שיווי משקל היא מסייעת לשמר תפיסה ראייתית יציבה ואוריינטציה גופנית. בזמן תנועה, במקרה של אבדן שיווי משקל, החיישנים בתוך האוזן מזהים תנועה ומתריעים בפני השרירים נוגדי כוח הכבידה לגרום לשרירים לבצע פעולה מפצה של מרכז הגוף, זרועות וראש. עם העלייה בגיל המשותב הולך ופוחת, לכן פוחתים הסיכויים שקשישים יוכלו לבצע פעולה מתקנת ולהימנע מנפילה על הקרקע. מנגנון שיווי המשקל מורכב בצורה עדינה ומשולבת כדי להתגבר על החיסרון המכאני, בכך שהבסיס שעליו אדם עומד או הולך צר מהקוטר ומהרוחב של הגוף. על מערכת זו לייצב את תנוחת הגוף, במקרה של איבוד שיווי משקל, למניעת נפילה, כאשר נפילה משקפת כישלון במנגנון ההתייצבות [4].

#### 2.1.2. הפרעות הליכה המאפיינות את הקשיש

הפרעות הליכה המאפיינות את הקשיש מהוות גורם ראשוני לנפילות ולחוסר שיווי משקל. שכיחותן של הפרעות הליכה עולה עם הגיל, ומהווה סמן ביולוגי להתפתחות של מחלות שונות, כלומר, ככל שאנו מתבגרים הפרעות ההליכה מעלות את הסיכון לנפילות [5]. הפרעות הליכה אצל קשישים נובעות ממחלות גופניות שונות ומירידה בתהליכי החשיבה המתפתחים על פני השנים. שכיחות הפרעות הליכה עולה ככל שמתבגרים ומהווה סימן להתפתחות מחלות שונות: מחלת לב, מחלות כלי דם, שברים, דלקת פרקים, מחלות נוירולוגיות כמו מחלת פרקינסון, אירוע מוחי, מחלות חוט השדרה, דמנציה ועוד. ארבעה מרכיבים נדרשים ליציבות ולשיווי משקל: עיבוד קוגניטיבי, תהליכים ביו-מכאניים, תהליכים תחושתיים ואוריינטציה במרחב. כל אלה מסייעים לנו לזוז מנקודה לנקודה (להתקדם במרחב) ולהתגבר על מכשולים בדרך. ההליכה תלויה בכוח שרירים ובגמישות מפרקים, בעיבוד אינפורמציה חושית – ראייה ושמיעה, בסבולת לב-ריאה, יציבות ושיווי משקל. אולם כדי לבצע הליכה בפועל, אנו זקוקים למשאבים קוגניטיביים. הליכה אינה פעולה אוטומטית, כפי שנהוג היה לחשוב בעבר. היא דורשת ניצול תפקודים עילאיים של המוח וקשורה ביכולות הקוגניטיביות הניהוליות. חשוב לזכור שהתפקוד הקוגניטיבי משתנה עם ההזדקנות. ככל שאנו מזדקנים, נפח המוח שלנו קטן, ועמו קיימת גם נסיגה ביכולות החשיבה הכוללות, מהירות תגובה עם הסחה, יכולת אומדן

מרחק, תפקודים ניהוליים, יכולת לבצע שתי משימות במקביל ועוד. קיימים ארבעה סוגים של הפרעות הליכה :

- הליכה הססנית - נובעת מהזדקנות המוח
- הליכה זהירה - יכולה לגרום אפילו להימנעות מהליכה, או להליכה איטית ופחד מפילה
- הליכה בבסיס רחב - הליכה בפישוק רגליים יכולה להיות ביטוי לירידה תפקודית על רקע ניווני או וסקולארי
- הליכה פרקינסונית - הליכה בדשדוש רגליים/גרירת רגליים, כמו הליכה בבוץ טובעני, ולסירוגין הופעה של קיפאון בתנועות. צורת הליכה נוספת בקטגוריה זו היא הליכת מרוץ, כאשר האדם מתחיל לרוץ בנטייה קדימה, ריצה אחרי מרכז הכובד.

### 2.1.3. נפילות

תופעת הנפילות בגיל המבוגר היא בעיה בריאותית ציבורית כלל עולמית. בקרב מדינות רבות בעולם נפילות הן אחד הגורמים העיקריים לתחלואה ותמותה בקשישים ועלולות לגרום לירידה תפקודית. כ-30% מבני ה-65 ומעלה מדווחים על נפילה אחת או יותר בשנה. מחקרים רבים עסקו בזיהוי גורמי הסיכון לנפילות. מקובל לחלק אותם לשתי קטגוריות: גורמים חיצוניים כגון תרופות ומכשולים בסביבה, וגורמים פנימיים (תלוי נבדק) כגון מצב בריאותי, מוגבלויות (בניידות, בראיה, בשמיעה ועוד) ומצב ריגשי או קוגניטיבי. נפילות קורות עקב מספר גורמי סיכון, כך שהסיכוי לנפילה גדל ככל שמעורבים יותר גורמי סיכון. לבנקרון וקימיאגורב [6] עקבו אחרי שכיחות הנפילות של דיירים בבית אבות בישראל לאורך חמש שנים. הגיל הממוצע של אוכלוסיית המחקר הייתה 85 שנה. נמצא ששכיחות הנפילות השנתית הייתה 1.13 נפילות לאדם, כאשר כל נפילה כזו פצעה את הדיירים בצורה חמורה. תופעה מדהימה בכל היבט רפואי אשר מדגישה עוד יותר את חשיבות המחקר והפיתוח בנושא זה. בעקבות מחקר זה תיארו המחקרים דמות סטטיסטית של דייר נייד הנוטה לנפילות נשנות כדלקמן: אישה בת 83 ומעלה, הלוקה במחלות לב וכלי דם פעילות, בעלת הפרעות תחושה כגון ירידה בראייה ובשמיעה, הסובלת ממחלות ניווניות במערכת העצמות והשרירים, או לאחר ניתוחים אורתופדיים. כמו כן, היא סובלת ממחלות זיהומיות פעילות. משמעות הדמות הסטטיסטית במחקר זה, בדומה למחקרים דומים, היא להוכיח קשר ישיר בין שכיחות נפילות בקרב קשישים לבין מצבם הבריאותי ובקשר ישיר לכך גם מספר התרופות שהם נוטלים בשל מצבם הבריאותי, כאשר מספר התרופות האופייני ל"קשיש/ה נופלת" היה חמש תרופות ויותר. כמו כן, הוכחה תלות הדדית בין שכיחות הנפילות לבין המצב התפקודי של הקשיש [7].

### 2.1.4. מחקרים קודמים

על מנת לקבל מידע נוסף על אופן הטיפול הקיים היום וההתמודדות בשמירה על הקשישים בביתם באמצעות ניטור והשגחה לצורך זיהוי נפילה או התדרדרות במצבם, בוצע איסוף נתונים באמצעות זיהוי מוקדם של גורמי סיכון שיש לשים לב אליהם ולשינוי בהם, וכמובן למידה ממחקרים קודמים שבוצעו אשר קשורים לנושא בדרכים שונות, בכדי לנסות לצמצם ואף למנוע נפילות בקרב מבוגרים בביתם. מאמר [8] עוסק במחקר

שבוצע בבית הספר להנדסת אלקטרוניקה ומדעי המחשב, אוניברסיטת קוויין מרי בלונדון, בריטניה. המחקר עוקב אחרי גישה עם ניטור נתוני חיישן LiDAR 2D, באמצעות שיטה למדידת מרחקים על ידי הארת אובייקט בקרן לייזר ומדידת הזמן של קרן האור מרגע ההארה ובחזרה למקלט, (מורחב בפרק 2.3) אשר מבצע שיוך של פעילויות המבוססות על מיקום המשתמש בחדר, באמצעות אימון רשת עצבית רקורסיבית שתזהה את פעילות האדם בחדר, זאת באמצעות סווג נתוני מיקום מדויקים ברמת סנטימטר. תוצאות מחקר זה סיפקו דיוק לוקליזציה ברמת סנטימטר של 88% כאשר זוהו 17 פעילויות יומיומיות ממוקדות הקשורות למיקום האדם. החיסרון הגדול במחקר זה הוא שאימון הרשת מתבצע באופן ספציפי לחדר בו היא מתקיימת, לכן בכל שינוי חדר יש לאמן את הרשת פעם נוספת. מאמר נוסף בנושא [9] עוסק במחקר שבוצע ביחידה לחקר מדעי המחשב ותקשורת במעבדת הרובוטיקה שבאוניברסיטת לוקסמבורג ואוניברסיטת ריי חואן קרלוס, אשר עוקב אחר אנשים באמצעות מידע מסורק LiDAR דו ממדי ועל ידי אימון רשת נוירונים קונבולוציונית. הסורק מסוגל לעקוב אחר זוגות רגליים בסביבה עמוסה. ישנו אפיון של המערכת המוצעת והערכת דיוקה באמצעות מערך נתונים ממאגר ציבורי. תוצאות מחקר זה מראות שכלי זה מספק דיוק טוב יותר מגלאי רגליים. החיסרון במחקר הוא שיש צורך באופטימיזציה של הרשת כדי לשפר את הביצועים. הכלי שנבנה צריך לקבל את מיקומי האנשים בזמן אמת ברגע שמתקבלים נתוני חיישן LiDAR כך שעכוב של 0.3 שניות, יכול להיות יותר מדי ארוך במצבים מסוימים, מאחר ונפילה היא אירוע שמתרחש במהירות הבזק. בנוסף, השימוש בנתונים, מזהה רגליים בחדר מבלי להתייחס לפעולות שאותו אדם מבצע. ישנם מחקרים נוספים אשר בוצעו במכשירים אחרים כגון מצלמות עומק וחיישנים שאינם שומרים על פרטיות המשתמש ולכן הם נמצאו פחות רלוונטיים.

### 2.1.5 מכשירים ואמצעי מדידה שונים

למרות התקדמות הטכנולוגיה ופיתוח המוצרים החדשים בשוק, הפתרונות הנוכחיים הקיימים עדיין מציבים אתגרים בפני פתרון הבעיה. מערכות מבוססות חיישנים לבישות, כוללות סוגים שונים של חיישנים על הגוף שיכולים למדוד פרמטרים חשובים כמו תאוצה, מהירות, כוחות מגנטיים, קצב לב, טמפרטורת גוף, רוויית חמצן, קצב נשימה, אלקטרודיוגרמה וכו'. ניתן להעביר את האותות המתקבלים באמצעות מערכת קווית או אלחוטית לצומת מרכזי לצורך עיבוד נוסף. מערכת בריאות מבוססת חיישנים לבישים, עשויה להיות מורכבת ממגוון רחב של רכיבים לרבות חיישנים, חומרים לבישים, מודולי תקשורת אלחוטיים, יחידת עיבוד, ממשק משתמש ואלגוריתמים מתקדמים לעיבוד נתונים וקבלת החלטות. עם זאת, פתרונות לבישים כגון שעונים או צמידים מיוחדים, לרוב אינם אידיאליים כאשר מטפלים במטופלים מבוגרים, מכיוון שהם צריכים לזכור ללבוש ולהטעין אותם, ולעיתים קרובות הם לא אוהבים את הטרחה בלענוד אותם. כמו כן, החיישנים הלבישים קשים להתקנה על הגוף ודורשים התאמות מקצועיות. בהסתכלות על חיישנים פסיביים, מרחב הפתרונות האפשריים הקיימים בשוק נע בין שתי גישות אפשריות. מצד אחד, ישנן מערכות פשוטות המשתמשות בחיישנים מסוג מבוסס יותר, למשל: חיישני תנועה אינפרא-אדום, הנקראים גם חיישני תנועה Passive infrared sensor (PIR). הם מותקנים על קירות או תקרות של בתי קשישים כדי לאסוף באופן רציף נתוני תנועה, הקשורים לפעילויות מוגדרות מראש בהיקף החיישנים. לרוב הם רגישים לחום כך שהחיישנים מזהים את נוכחות המשתמשים בחדרים על ידי ניצול השינויים בטמפרטורה. כמו כן יש חיישני רדאר, אשר יכולים לזהות ולמדוד כל תנועה בנוכחות עומס נייח ברקע, מכיוון שהוא יכול לחזור מכשולים חזקים כמו ריהוט וקירות. בנוסף, יש את חיישני הרצפה אשר ממלאים תפקיד חשוב בפיתוח סביבות חיה בעלות פולשנות נמוכה. יתר על כן, פתרונות אלו פחות פולשניים מבחינת חדירה לפרטיות, כלומר, רק שם האירוע

וחותמת הזמן של החיישן מתועדים, ובנוסף אינם דורשים הכשרה של נתונים, אך לרוב הם אינם מספקים מספיק פרטים על ההתנהגות בפועל של המשתמש, אלא אם חיישנים רבים מפוזרים בבית. מצד שני, ישנם פתרונות יותר חודרניים, המשתמשים במצלמות או מיקרופונים עם שיטות בינה מלאכותית מתקדמות כדי לגזור ולהבין את התנהגות המטופל ומעמדו. פתרונות אלו מספקים רמת פירוט מעולה ומאפשרים ניטור בזמן אמת של מטופלים, כלומר צפייה/האזנה לזרם חי. למשל: חיישני וידאו הם חיישני הסביבה הנפוצים ביותר לטיפול בקשישים. עבודות מחקר רבות בוצעו בסביבה מסייעת באמצעות מצלמות וידאו עבור יישומים שונים, כגון איתור דיירים וזיהוי פעילותם בבתיהם. מצלמות מותקנות על הקירות או התקרות כדי לזהות פעילות באמצעות מיצוי צורת גוף, ניתוח תכונות ולמידת מכונה. בין היישומים הרבים, טכנולוגיית ניטור וידאו שימשה בעיקר לאיתור פעילויות חיי היומיום ונפילות, או אירועים משמעותיים אחרים. בנוסף, קיימים חיישני קול כגון מיקרופונים המשמשים לזיהוי אירועים שונים כמו פעילויות יומיומיות, למשל, הצליל שנוצר מנפילה של חפץ או אדם. עם זאת, חיישנים אלה דורשים כמויות עצומות של נתוני הכשרה, וחשוב מכך, מציגים חששות משמעותיים בנושא פרטיות ואתיקה [10].

## 2.2 Robot Operating System

Robot Operating System (ROS) הינה חבילת קוד-פתוח (open-source) המשמשת לתיווך בין המכונה למחשב. יש לציין כי ROS אינה מערכת הפעלה אלא אוסף של מסגרות (Frameworks) לפיתוח תוכנת רובוט. ניתן לסווג את התוכנות ב-ROS לשלוש קטגוריות [11]:

- כלים בלתי תלויים בשפה ובפלטפורמה המשמשים לבנייה והפצה של תוכנות מבוססות ROS
- שימוש בספריות ROS המקלות על עבודתו של המתכנת על ידי כתיבה בצמתים או קודקודים (nodes), לפרסם (Publish) ולהירשם (Subscribe) לנושאים (Topics). ניתן ליישם ספריות כאלו בכל שפת תכנות שהיא, אך נהוג להשתמש ב-Cpp או ב-Python [12]
- חבילות (packages) המכילות אחד או יותר מספריות ROS (nodes, libraries) ומטרתן לספק שימוש חוזר בתוכנה באופן קל לשימוש [13]

### 2.2.1 Rviz


ליבת ROS (Core) מוגברת על ידי מגוון של כלים שונים, המאפשרים למשתמש לראות נתונים באופן ויזואלי ולשמור אותם [14]. בפרויקט זה נעשה שימוש בכלי שנקרא Rviz המאפשר להמחיש באופן ויזואלי ותלת-ממדי את הרובוטים, את סביבת עבודתם, ונתונים מחיישן כגון LiDAR המפיק ענן נקודות (Point-Cloud).

## 2.3. LiDAR

LiDAR הינה שיטה למדידת מרחקים על ידי הארת אובייקט בקרן לייזר ומדידת הזמן של קרן האור מרגע ההארה ובחזרה למקלט. ניתן להשתמש בשיטה זו כדי ליצור ייצוג תלת-ממדי של המרחב. LiDAR הינו ראשי תיבות של "Light Detection And Ranging" [15]. שימושים נפוצים ב-LiDAR כוללים מיפוי ברזולוציה גבוהה עם יישומים בתחומים רבים כגון מדידת מקרקעין, גאודזיה, גאוגרפיה, גאולוגיה, סייסמולוגיה, הנחיית רובוטים באמצעות לייזר, אוטונומיזציה של רכבים ועוד. מדידת המרחק מתבצעת על ידי שימוש בעקרונות פיזיקליים בסיסיים [16].

$$d = \frac{ct}{2} \quad (2.1)$$


כאשר  $d$  הינו המרחק,  $t$  הזמן ו- $c$  עבור מהירות האור.



איור 2.1: מדידת המרחק של קרן הלייזר בטכנולוגיית LiDAR

### 2.3.1 LeiShen Intelligent System's 16-Line Mechanical LiDAR

בפרויקט זה נעשה שימוש ב-LiDAR C-16 (LiDAR) של חברת LeiShen Intelligent System. הוא בנוי מ-16 זוגות של מקריני לייזר ומקלטים במישורים שונים (זוויות שונות) אשר מותקנים על המסבים, ראה איור 2.2. מתבצעת סריקה פנורמית של  $360^\circ$  על ידי סיבוב המנוע הפנימי ובמהירויות סיבוב של 5 Hz, 10 Hz, 20 Hz. התקן זה מוגדר כ- 'Class 1' בבטיחות לייזר, כלומר הוא בטוח לשימוש תחת כל תנאי השימוש הסטנדרטיים (אין להתבונן בלייזר עם כלים אופטיים כגון טלסקופ ומיקרוסקופ אלא רק עם עיניים חשופות) ולא ניתן לעבור את החשיפה המרבית המותרת, Maximum permissible exposure (MPE), עם עיניים חשופות [18].



## איור 2.2: תיאור מבנה ה-LiDAR של LeiShen Intelligent System's C-16

דגם זה עושה שימוש באותו העקרון אשר מוצג במשוואה (2.1) אך הזמן,  $\Delta t$ , מוגדר כך שכאשר המקרן יורה את קרן הלייזר, שעון העצר הפנימי מחשב את הזמן  $t_1$  ועוצר ב-  $t_2$  כאשר המקלט מקבל את האנרגיה החלקית המוחזרת מאובייקט מסוים [17].

כלומר:

$$d = \frac{c\Delta t}{2} = \frac{c(t_2 - t_1)}{2} \quad (2.2)$$


## 2.4. בינה מלאכותית

### 2.4.1. ניתוח אשכולות

ניתוח אשכולות (Clustering) הינו קיבוץ של אובייקטים לקבוצות (אשכולות) כך שהאובייקטים הנמצאים באותה קבוצה דומים זה לזה יותר מאשר לאובייקטים השייכים לקבוצות אחרות [20]. לשם ביצוע משימה זו פותחו שיטות שונות ואלגוריתמים שונים. ניתן לחשוב על ניתוח אשכולות כבעיית אופטימיזציה רב-משימתית, כלומר בעיה בה יש למקסם יותר מפונקציית מחיר אחת בו זמנית [21]. הפרמטרים בהם משתמשים האלגוריתמים השונים, כגון פונקציית המרחק וצפי מספר הקבוצות, תלויים במאגר המידע האינדיבידואלי בו נעשה שימוש.

#### 2.4.2. מכונת תמך וקטורי

מכונת תמך וקטורי או באנגלית Support-vector machine (SVM) היא טכניקה של למידה מונחית (supervised learning), כאשר הכוונה במילה "מונחית" הינו השימוש במאגר מידע שאנחנו יודעים את התיוגים שלו מראש, המשמש לניתוח נתונים וסיווג לקבוצות על סמך ניסיון קודם. בטכניקה זו כל נקודה במאגר המידע, מיוצגת על ידי וקטור מממד  $p$  שגודלו קבוע ובאמצעות על-מישור (מרחב ממימד  $p - 1$  בתוך מרחב מממד  $p$ ), כך שהמרחק בין העל-מישור, המחלק את הנקודות המסווגות, לבין הנקודות הכי קרובות אליו יהיה מקסימלי [12], כמתואר באיור הבא.



איור 2.3: העל-מישור, H3, מפריד בין שתי הקבוצות השונות עם גבול שוליים מקסימלי

כאשר H1 אינו מפריד בין הקבוצות השונות, H2 מפריד בין הקבוצות עם גבול שוליים קטן, והצירים הם שני מאפיינים בעלי ערך ממשי אשר ממפים מרחב דו ממדי.


#### 2.4.3. מסנני חלקיקים

מסנני חלקיקים, באנגלית Particle filters (PFs) הם אלגוריתמים של למידה מבוססי דגימות לרשתות בייסיאניות דינאמיות (Dynamic Bayesian networks, DBNs) והם מאפשרים לטפל בכל סוג התפלגות ולפתור בעיות פילטור (סינון) בתהליכים סטוכסטיים [17].

#### 2.4.4. רשת עצבית מלאכותית

רשת עצבית מלאכותית (Artificial Neural Network) הינה רשת נוירונים אשר פותחה בהשראת המוח האנושי. מכיוון שהמוח האנושי מכיל נוירונים המסוגלים ליצור דחפים עצביים כתגובה לגירויים מסוימים ובאמצעותם לתקשר עם תאים אחרים, פותחו בהשראתו מודלים מתמטיים כדי לנסות לדמות מבנה זה. להלן ציטוט מספרו המפורסם של Michael Nielsen, הנקרא *Neural Networks and Deep Learning*: "רשתות עצביות הן אחת מפרדיגמות התכנות היפות ביותר שהומצאו אי פעם. בגישה הקונבנציונלית לתכנות, אנחנו אומרים למחשב מה עליו לעשות, ובגדול בעיות מתגלגלות להרבה משימות קטנות ומוגדרות במדויק שהמחשב יכול לבצע בקלות. לעומת זאת, ברשת עצבית אנחנו לא אומרים למחשב איך לפתור את


הבעיה שלנו. במקום זאת, היא לומדת מנתוני תצפית, ומגלה את הפתרון שלה לבעיה שעל הפרק" [22]. רשת מסוג זה מכילה קלטאים ופלטאים ובדרך כלל ביניהם גם "שכבות חבויות" (Hidden Layers), כמתואר באיור הבא:



איור 2.4: תיאור רשת עצבית מלאכותית

#### 2.4.4.1. נוירון ומשקולות

נדון תחילה בנוירון פשוט הנקרא פרספטרון (Perceptron) אשר מקבל מספר קלטאים  $x_1, x_2, \dots, x_n$  בינאריים ומייצר מהם פלט בינארי כמתואר באיור הבא:



איור 2.5: קלט ופלט בנוירון פרספטרון

כדי לחשב את הקלט, נציג ערכים ממשיים להם נקרא "משקולות"  $w_1, w_2, \dots, w_n$  אשר מבטאים את חשיבותם בהתאם לכניסות השונות לפלט. לבסוף, הפלט של הפרספטרון (0 או 1) נקבע על ידי המשוואה הבאה:

$$Output_{Perceptron} = \begin{cases} 0, & \sum w_j x_j \leq threshold \\ 1, & \sum w_j x_j > threshold \end{cases} \quad (2.3)$$


כעת נדון בנוירון הנקרא סיגמויד (Sigmoid) אשר מקבל מספר קלטאים ומייצר פלט בדומה לפרספטרון. בניגוד לפרספטרון, מקבל פלטים בין 0 ל-1 ומייצר מהם פלט שגם הוא בין 0 ל-1. בהינתן הקלטאים,



המשקולות ו-bias אשר מבטא מינוס ה-threshold בדומה למתואר במשוואה (2.3), ניתן לחשב את פלט הסיגמויד באופן הבא:

$$\sigma = \frac{1}{1 + \exp(-\sum_j w_j x_j - b)} \quad (2.4)$$

כאשר b הינו ה-bias של הנוירון.



איור 2.6: פונקציית הסיגמויד  $\sigma$

לצורתה האלגברית של פונקציית הסיגמויד אין חשיבות רבה כמו שיש לחשיבות הצורה שלה; אם הסיגמויד הייתה פונקציית מדרגה אז היא הייתה הופכת להיות פשוט פרספטרון.

#### 2.4.4.2 Gradient Descent

Gradient Descent היא שיטת אופטימיזציה איטרטיבית מסדר ראשון למציאת מינימום מקומי של פונקציה. בשיטה זו, נעשה צעד נגדי לגרדיאנט ביחס לנקודה הנוכחית. השיטה עובדת כך שבכל שלב של ההפעלה היא מתקדמת לכיוון הפוך לגרדיאנט (כיוון שהגרדיאנט מראה את השיפוע כלפי מעלה) כך שבכל שלב יש התקדמות נגד השיפוע המקסימלי, עד שמגיעים לנקודה מספיק נמוכה המוגדרת בתנאי העצירה [23]. באיור הבא ניתן לראות קוד פייתון של האלגוריתם Gradient Descent.

```

1 # x0 - initial guess
2 # df - gradient of function
3 def gradient_descent(x0, df):
4     cur_x = x0 # The algorithm starts at x0
5     gamma = 0.01 # step size multiplier
6     precision = 0.00001
7     previous_step_size = cur_x
8     while previous_step_size > precision:
9         prev_x = cur_x
10        cur_x += -gamma * df(prev_x)
11        previous_step_size = abs(cur_x - prev_x)
12    return cur_x

```

איור 2.7: קוד פייתון של האלגוריתם Gradient Descent

### **2.4.4.3 Backpropagation**

המונח Backpropagation מתייחס לעדכון המשקולות השונות תוך כדי הלמידה, בשאיפה שהשגיאה תרד בכל פעם שמעדכנים את המשקולות וכך להגדיל את הדיוק. ב- Backpropagation מתבצעת פעולה של שליחת הנתונים משכבת הקלט לשכבת הפלט ואז כל הדרך חזרה אל שכבת הקלט. פעולה זאת נקראת Epoch. בכל Epoch, הרשת מעדכנת את משקלם של הנוירונים השונים ברשת. Gradient Descent הינו אחד האלגוריתמים היותר נפוצים למציאת קבוצת המשקולות שמקטינות את השגיאה ב- Backpropagation.

### **2.4.4.4 בעיית הגרדיאנט הנעלם (The Vanishing Gradient Problem)**

בעיית הגרדיאנט הנעלם היא למעשה תוצר של רשתות למידה עמוקה, בהן השכבות השונות ברשת לומדות בקצב שונה ולכן ישנה אי יציבות. הבעיה היא שהגרדיאנט בשכבות הראשונות של הרשת הוא תוצר של המשקולות והשכבות הבאות. כלומר, כאשר ישנן הרבה שכבות ברשת, יכולה להיווצר בעיית יציבות. הדרך היחידה בה השכבות השונות ברשת יוכלו ללמוד באותו קצב היא על ידי מנגנון באלגוריתם הלמידה עצמו.

### **2.4.4.5 רשת LSTM**

רשתות LSTM פותחו על מנת להתמודד עם בעיית הגרדיאנט הנעלם המוזכרת לעיל. לרשת מסוג זה יש חיבורי משוב (Feedback connections) והיא יכולה לעבד לא רק נקודות נתונים בודדות כגון תמונות, אלא גם רצפים שלמים של נתונים כגון דיבור או וידאו. יחידת LSTM מורכבת מתא הזכר ערכים על פני מרווחי זמן שרירותיים ושלושת השערים מווסתים את זרימת המידע אל התא וממנו. רשתות LSTM מתאימות היטב לסיווג, עיבוד וביצוע תחזיות על סמך נתוני סדרות זמן מכיוון שיכולים להיות פערים של משך זמן לא ידוע בין אירועים חשובים בסדרת זמן.

## **2.5 Vicon**


מערכת ה-Vicon היא מערכת ללכידת תנועה לביצוע ניתוחים קינמטיים, בעלת יכולת לספק מודל תלת ממדי ויזואלי של מהלך הניסוי, כך שניתן לקבל את מיקומי המפרקים כקובץ נתונים לתוכנת האקסל. הנתונים המופקים מתוכנת האנליזה של ה-Vicon נותנים מידע בשלושת צירי המרחב  $X, Y$  ו- $Z$  עבור מיקום כל מפרק בקצב דגימה של 120 Hz.

### **2.5.1 מצלמות**

מערכת זו כוללת 16 מצלמות אינפרא-אדום אשר פועלות בו-זמנית בתדירות של 120 Hz. תמונות המצלמה ממופות למערכת קואורדינטות תלת ממדית לתוכנת Vicon Nexus באמצעות אלגוריתם טרנספורמציה לינארית ישירה [24].

## 2.5.2. מרקרים וחליפה

נבדקי הניסוי לובשים חליפת גוף ייעודית עליה 39 מרקרים מחזירי אור ובעלי רדיוס של 14 מ"מ הממוקמים בנקודות ציון ספציפיות. שני מרקרים נוספים הונחו על גבי פלטפורמת ה-BaMPer כדי לעקוב אחר תזוזת הפלטפורמה.



איור 2.8: מיקום המרקרים על גבי הנבדק

## טבלה 2.1: משמעות שמות המרקרים

משמעות בלועזית	תיאור המפרק על פי איור 2.8
Sternum	STRN
Left/Right Shoulder	LSHO / RSHO
Left/Right Elbow	LELB / RELB
Left/Right Wrist	LWRB/ RWRB
Left/Right Finger	LFIN/ RFIN
Left/Right Anterior Superior Iliac	LASI/RASI
Left/Right Knee	LKNE/RKNE
Left/Right Ankle	LANK/RANK

### 2.5.3. Vicon-Nexus

כלל הנתונים הנקלטים במערכת מעובדים באמצעות תוכנת ה-Vicon-Nexus, זהו הכלי הטוב ביותר בשוק לעיבוד, מידול ואנליזה תנועה. תוכנה זו מזהה "חורים" (gaps) במדידות, ובוחנת את איכות התיוג שלהן באופן אוטומטי. בנוסף, היא מאפשרת סקירה כללית, וויזואלית של הנבדק ואפשרויות שונות למילוי ה-gaps לשם תיקון הנתונים במידת הצורך. לאחר ניתוח הנתונים ועיבודם בתוכנה זו, ניתן להנפיק קובץ מידע מלא אודות הניסוי [25].

## 2.6. BaMPer-Balance Measure & Perturbation

מערכת המאפשרת הליכה רציפה ללא הגבלה, מספקת תאוצה של בסיס ההליכון והפרעה בהליכה לאורך מהלך מקסימלי של 20 ס"מ לכל כיוון. המתקן נשלט באמצעות ממשק ממוחשב, אשר שולט בתנועת הבמה ויוצר פרטורבציות- הפרעות (תנועות פתאומיות של הבמה). ההליכון מוקף בבמת עץ באותו מישור אופקי, על-מנת שבזמן הפרעה הנבדק יוכל לבצע צעד לכיוון הבמה ולהתייצב. הבמה עומדת בעומס דריכה של אדם, והיא מתוכננת כך שהחיבור להליכון יהיה על מישור אחד ללא יכולת של הנבדק למעוד ו/או ליפול. ישנו חיבור לרתמת בטיחות אשר מטרתה לשאת אדם המשתמש במתקן במצב של איבוד שיווי משקל ולמנוע כל פגיעה בו [26].

### 2.6.1. ביצועי המערכת המכאנית

- הליכה רציפה ללא הגבלה (הליכון), ובמישור אחד ללא שיפועים
- תאוצת המערכת: עד  $9.81 \frac{m}{s^2}$
- מהירות מרבית של ההליכון: 10 קמ"ש
- זמן היערכות מחדש לאחר פרטורבציה: 15 שניות
- פרטורבציה לצדדים: תאוצה עד  $9.81 \frac{m}{s^2}$ , ומהירות מקסימאלית של 3.6 קמ"ש. מרחק מהלך ההפרעה: עד 20 ס"מ
- פרטורבציה קדמית/אחורית: תאוצה עד  $1.5 \frac{m}{s^2}$ , מהלך תנועה עד 5.9 מטר. נתונים אלו מתייחסים למצב פרטורבציה קדמית, כאשר ההליכון במצב ריצה במהירות של 10 קמ"ש. במצב זה נדרשת תנועה ארוכה של ההליכון מכיוון שהנבדק יכול להימצא זמן רב באוויר עקב הריצה, בנוסף האצת ההליכון מתווספת לתנועה הקיימת ומהירות זו מספיקה על מנת להוציא משיווי משקל
- משקל העמסה מותר: אדם עד 100 ק"ג

### 2.6.2. משתנים שיקבעו על ידי המפעיל

- מהירות ההליכה בהליכון באופן רציף

- כיוון ההפרעה : קדימה / אחורה / ימינה / שמאלה או באופן אקראי
  - מרחק התזוזה\*
  - גודל התאוצה והתאוצה\*
  - זמן השהייה עד להפעלת ההפרעה יקבע על-ידי המשתמש\*
- \* לכל אחד מפרמטרים אלו תינתן האופציה לבחירה רנדומלית מתוך טווח מרחקים שיוגדר על ידי המשתמש ועומד בדרישות המערכת.

### 2.6.3. עיקרי המערכת המכאנית

המסגרת התחתונה מהווה את בסיס המערכת. במרכז הבסיס ממוקמת מערכת ההנעה לצדדים האחראית על הפרעות ההליכה ימינה ושמאלה. מערכת ההנעה מורכבת מ-9 גלגלי תזמון המחוברים לגיר ומנוע, המניעים רצועת תזמון שתחובר לחלק העליון. מערכת ההליכה מותחבת לחלק התחתון והוא בנוי מ-9 פרופילים מלבניים, עליהם יושבת פלטת עץ וביניהם בולמי זעזועים מגומי. ציר תנועתו מקביל לציר Y של המערכת. ישנה חצאית היקפית למערכת והיא במת הבטיחות, היא בנויה מבמת עץ צפה המתחברת לחלק העליון, תפקידה ליצור הפרדה בין הנבדק למערכת. רתמת הבטיחות מתחברת לתקרת המעבדה והן מהוות אבטחה לשמירה על הנבדק.



איור 2.9: צילום מקורי של מערכת ה-BaMPer הכוללת את הבמה והרתמה

#### **2.6.4 מערכת הבקרה ותכנת ה- Balance Tutor**

מערכת הבקרה אחראית להפעלת המנועים ומשלבת עיבוד נתונים באמצעות מחשב ובקר. ממשק המשתמש הגרפי הוא תוכנה הנקראת Balance Tutor והיא ידידותית למשתמש. התוכנה בעלת יכולת עצירת חירום בכל שלב, ושליטה מלאה על ההפרעות כמו גם על תנועת ההליכון הרציפה.

ישנה יכולת לקבוע את כל הפרמטרים באופן מדויק, ויכולת אי צפיות, כך שהנבדק לא יוכל לדעת את הזמן בין הפרעה להפרעה, הכיוון, נקודת היציאה, הטווח, התאוצה וכדומה, זאת מכיוון שבגמר כל פעולה המערכת חוזרת ראשית למרכז ומשם מבצעת את הפעולה הבאה.

בנוסף ישנה יכולת תצוגת נתונים גבוהה הכוללת תצוגת טיימר בין הפרעה להפרעה, תצוגת מספר ההפרעה מתוך כלל הפרעות הניסוי, תצוגת כל הפרמטרים שנבחרו בהפרעה ספציפית, ולבסוף יצירת טבלה המרכזת באופן אוטומטי את נתוני הניסוי.

#### **2.6.5 פרוטוקול**

במהלך שימוש במערכת ניתן לבצע כל פרטורבציה בנפרד וניתן להגדיר מראש פרוטוקול קבוע שמכיל מידע כגון אילו פרטורבציות יהיו בדיוק, לאיזה כיוון, באיזו עוצמה ובאיזו תדירות, כך שהמערכת תפעל לפיו באופן אוטומטי כפי שהוגדר לה. בניסוי שלנו השתמשנו בפרוטוקול קיים שנכתב בעבר על ידי פרופסור איציק מלצר.

### **3. מפרט דרישות המערכת**

בפרק זה נדון באלמנטים שונים של מערכת החישה על מנת להגיע למוצר הסופי העונה על הדרישות ההכרחיות לקיומו. הדרישות נכתבו לפי סדר חשיבותן.

#### **3.1 דרישות כלליות**

- א.** יכולת לזהות נפילות ולהזעיק עזרה במידת הצורך.
- ב.** כיבוד מלא של פרטיות המשתמש אשר צריכה להישמר במלואה, ולכן לא נעשה שימוש במצלמת אינטרנט או בחיישנים לבישים או חודרניים לזיהוי וניטור מוקדם בתוך הבית.
- ג.** עמידה בבטיחות לייזר על מנת למנוע תאונות ובפרט תאונות הקשורות לפגיעה בעיניים.
- ד.** מדידה של הפרמטרים החשובים לניטור וזיהוי סיכונים לאורך זמן.
- ה.** מניעת התחממות יתר של מערכת החישה אשר צריכה להיות פעילה בזמנים מוגדרים מראש, אך באופן כללי תהיה פעילה ברוב שעות היום.
- ו.** מערכת חישה המתאימה לכל חלל ביתי שהוא, ולא כזאת אשר תוכננה לעבוד בחדר מסוים.

## 4. בעיות התכן ואלטרנטיבות לפתרון

בפרק זה מוצגות הבעיות העיקריות שעלו במהלך הפרויקט ופתרון. כחלק מהפתרון, הוצעו חלופות שונות אותן נציג בטבלת ההשוואה שבהמשך.


### 4.1 גילויי שווא

במהלך הפרויקט הוחלט לעשות שימוש באלגוריתם זיהוי האנשים של Kenji Koide [27] עליו נבצע שינויים ותוספות על פי הצרכים והדרישות של הפרויקט. תוך שימוש באלגוריתם זה, המבוסס רשת נירונים מאומנת ועם מאגר נתונים הנלקח מ-LiDAR של חברת Velodyne, הבנוי מ-32 זוגות של מקריני לייזר ומקלטים במישורים שונים, נתקלנו בבעיה של ריבוי False Positives. כלומר, האלגוריתם מזהה עצמים שהם לא אנשים, כגון כסאות ועמודים, בתור אנשים. אלגוריתם זה עושה שימוש בפרמטרים ובהיפר-פרמטרים רבים על מנת לסווג באופן בינארי את המקבצים השונים הנקלטים בזמן אמת. מכיוון שהאלגוריתם המקורי תוכנן לעבוד בצורה הטובה ביותר עם LiDAR הבנוי מ-32 מישורים שונים ומכיוון שחלק מהפרמטרים שערכם הנומרי נבחר על ידי ניסוי וטעיה מתאימים לתצורה המסוימת הזו, אין זה מפתיע שנתקלנו בבעיה זו. מכיוון שמכשיר המדידה שברשותנו הינו בעל רזולוציה נמוכה, ניסינו למזער את גילויי השווא על ידי ניסוי וטעיה. ערכנו מספר רב של ניסויים בהם בדקנו באילו מצבים האלגוריתם נכשל, ועל ידי שינויים בפרמטרים השונים כגון מספר הנקודות המינימלי והמקסימלי באשכול, מידות האשכול בצירים השונים ועוד, הצלחנו לצמצם משמעותית את ה-False Positives.

תחילה האלגוריתם זיהה כל תזוזה במרחב ונקלטו מספר רב של עצמים בחדר (גם אנשים שנעו בטווח הנסרק וגם עצמים בודדים כמו כסאות או קופסאות שזוהו בגובה על מדף), לאחר השינויים והניסויים שערכנו, ובנוסף לכך ששינינו את מיקום הניסוי, הצלחנו להגיע למצב בו לרוב יש זיהוי רק של אדם המתהלך בחדר, אך בעת ישיבה על כיסא, הזיהוי התפצל לשניים - אדם וכיסא.

### 4.2 "רעשים" במדידת המרחק האוקלידי

על מנת למדוד את הפרמטרים החשובים לניטור וזיהוי סיכונים אצל קשישים, התחלנו מהפרמטר הפשוט ביותר לחישוב, המרחק האוקלידי אשר עובר הקשיש בהיותו באזור המדגם. על ידי שימוש בפונקציית הזמן (time) ב-Python, נוכל למדוד את הפרשי הזמנים בין המיקומים העוקבים בכל רגע נתון ומשם לגזור את המהירויות והתאוצות של המשתמש בצירים  $x$  ו- $y$  המקבילים לאדמה. יש לציין כי ציר  $z$ , הניצב לאדמה, הינו מרכז האשכול ולכן אין לו משמעות פיזיקלית אך נוכל להיעזר בו בהמשך, כאשר נרצה להבחין בנפילה או בכמעט נפילה. באיור הבא ניתן לראות את מערכת הצירים כפי שהיא מופיעה בכלי Rviz.



איור 4.1: מערכת הצירים בכלי Rviz

המרחק האוקלידי חושב על ידי המשוואה הבאה:

$$d_{Euclidean}(x_i, y_i) = \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2} \quad (4.1)$$

כאשר  $x_i$  ו- $y_i$  הן קואורדינטות האשכול, ביחס ל-LiDAR, המסווג כהולך רגל בזמן  $t_i$  ו- $i=1,2,\dots,n$ .

בהנחה שהמשתמש שהה באזור המדגם עד אשר נלקחו  $n$  מדידות, אזי המרחק הכולל שעבר הינו:

$$d_{Euclidean} = \sum_{i=1}^{n-1} d_{Euclidean}(x_i, y_i) \quad (4.2)$$

הבעיה היא שחישוב זה כשלעצמו לא לוקח בחשבון את הרעשים בענן הנקודות המתקבל ממכשיר המדידה, לכן בניסויים שנערכו גם כאשר הנבדק עמד במקום, המרחקים הלכו וגדלו. כדי לפתור בעיה זו, נעשה שימוש במסנן High-pass filter (HPF) כדי לסכום רק מרחקים הגדולים מערך מסוים, אשר נקבע על ידי ניסוי וטעייה, ובכך למנוע את ההוספה של הרעשים למרחק האוקלידי הכולל. הוספת מסנן HPF פתר בעיה אחת, אך גורם לכך שכאשר הנבדק הולך במהירויות נמוכות, כמצופה מקשישים, המרחקים בין נקודות עוקבות לא מתווספים למרחק הכולל מכיוון שבכל פרק זמן מרחק זה עובר סינון שכן הוא קטן מערך הסף שהוגדר. על מנת לפתור בעיה זו נעשה שימוש במסנן נוסף, הנקרא ממוצע נע או באנגלית Simple moving average (SMA), על קואורדינטות האשכול המסווג, כלומר במקום לחשב את המרחק האוקלידי בין כל מדידה למדידה, חושבו המרחקים האוקלידיים בין הממוצעים של כל  $n$  מדידות עוקבות. כאשר  $n$  נקבע על ידי ניסוי וטעייה. השאיפה היא שקביעת הפילטרים תתאים בעתיד לכל נבדק ללא צורך בכיול נפרד עבור כל אדם.

### 4.3. רזולוציית מכשיר המדידה

רזולוציית מכשיר המדידה מתייחסת לגודל הקטן ביותר המייצג אובייקט או פרט בתמונה. לדוגמה, בעיבוד תמונה, ככל שהרזולוציה גבוהה יותר כך גם גודל הפיקסלים קטן יותר, ולהפך. בפרויקט זה יש למדוד בזמן אמת כמה שיותר פרמטרים אשר באמצעותם נוכל לאמוד התדרדרות בשיווי המשקל אצל קשישים תוך שמירה על הפרטיות בביתם. הבעיה היא שחלק מהפרמטרים אשר יכולים לסייע במשימה זו, כגון גובה הצעד



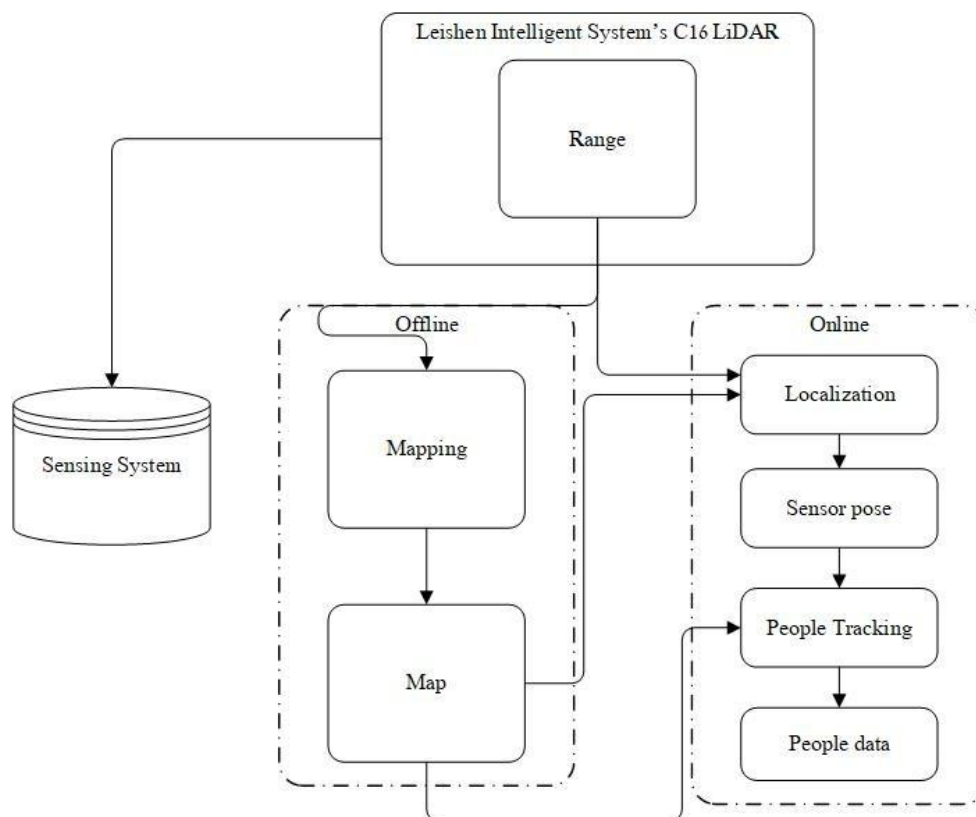
מעל הקרע (foot clearance), דורשים מכשיר מדידה בעל רזולוציה גבוהה. העלות של LiDAR ברזולוציה גבוהה יקרה בצורה בלתי רגילה, בעוד שהחלופה המקבילה ברזולוציה נמוכה הרבה יותר משתלמת. לכן, לא נלקחה בחשבון האלטרנטיבה היקרה. בטבלה 4.1, יוצגו חלופות עבור מכשיר המדידה כאשר החלופה הנבחרת היא חלופה 1.

**טבלה 4.1: חלופות עבור מכשיר המדידה**

חלופה 2: Stereolabs' ZED 2		חלופה 1: Leishen's C-16 LiDAR		
פלט ווידאו (Mode, FPS, Resolution)	חיישן שני חיישני 4M פיקסל עם פיקסלים של $2\mu$	אנכית $2^\circ$ (16 – channel)	אופקית $0.09^\circ$ ( $360^\circ$ )	רזולוציה
2.2K, 15, 4416x1242 1080p, 30/15, 3840x1080 720p, 60/30/15, 2560x720				
דיוק העומק קטן עם מחסור במידע עד כדי אי יכולת לקלוט עומק בחשיכה מוחלטת. כמו כן, הדלקה וכיבוי של האור משפיעים על איכות מיפוי העומק.		יכולת תפעול תחת אור השמש וגם בחשכה		השפעת תנאי התאורה
449\$		1499\$		מחיר לפני משלוח ומכס
אפליקציית ZED-SDK מקנה גישה לזיהוי אובייקטים, מעקב שלד, מעקב מיקום, לוקליזציה ומיפוי סימולטני. יתרון נוסף של מצלמת הסטריאו ZED-2 הינו רזולוציה וקצב פריימים גבוהים		אינו פוגע כלל בפרטיות המשתמש יכולת ליצר מודלים תלת ממדיים ולסווגם ניתן לקבל תוצאות די מדויקות ועקביות		יתרונות
יכול לפגוע בפרטיות המשתמש או ליצור תחושה של פגיעה בפרטיות מצידו		רועש עקב רזולוציה אנכית נמוכה ביחס למרחק הדגימה האופקי. מורכב באופיו ולכן דורש הבנה עמוקה של החיישן וניסיון		חסרונות

## 5. תכן רעיוני של המערכת

איור 5.1 מציג סקירה כללית של המערכת המוצעת. במערכת זו, מערכת החישה ממוקמת בחלל החדר, למשל באחת הפינות, או צמוד לקיר בסלון, על מנת לא להפריע למשתמש בפעולותיו היום-יומיות, בגובה מסוים אותו נקבע בהמשך, וללא הפרעות בשדה ראייתו של החיישן. מערכת החישה מצוידת ב-LiDAR תלת-ממדי אחד השווה בחלל הדגימה. ה-LiDAR התלת-ממדי מספק נתוני טווח של 360 מעלות וב-5 הרץ. למרות שהחיישן מתאפיין בטווח מדידה של 360 מעלות, נעדיף שלא למקמו במרכז החדר, מכיוון שהוא יהווה מכשול פיזי עבור הקשישים, וניתן להסתפק במדידות בטווח של 180 מעלות בלבד. התהליך של המערכת המוצעת מורכב משני שלבים ; (1) מיפוי סביבתי לא מקוון (2) מיקום מקוון של החיישן ומעקב אחרי הקשיש על פי אלגוריתם זיהוי האנשים של Kenji Koide [27]. מיקומו של הקשיש מתואר בזמן אמת על ידי מערכת צירים קרטזית אינרציאלית כמתואר בתת-פרק 4.2, רעשים במדידת המרחק האוקלידי. על ידי ווקטור המיקום ניתן לחלץ פרמטרים שונים ובעזרתם ניתן לזהות סיכונים, התדרדרות בשיווי המשקל, נפילות וכמעט נפילות ובמידת הצורך אף להזעיק עזרה. על מנת לספק לצרכן מעקב יעיל ואחיד, בכל פרק זמן מסוים תפיק המערכת גרף ביצועים.




איור 5.1: סקירה כללית של המערכת המוצעת



איור 5.2: עקרון תהליך פיתוח האלגוריתם

### 5.1. תכנן למתקן מערכת החישה

מערכת ה-LiDAR מותקנת בבית הקשישים ולכן ישנה חשיבות רבה לנראות המוצר ובטיחותו. בפרק זה נציג את התכנן הראשוני למעמד המוצר שמטרתו מלבד האסתטיקה, היא לתפוס את חיישן ה-LiDAR בצורה כזו שלא ייפול עקב רעידות וואו מכות לא צפויות. מכיוון שעלות החיישן יקרה מאוד יש למתקן זה חשיבות כלכלית רבה. מכיוון שאנו לא רוצים שמערכת החישה תפריע לקשיש בחיי היום יום, נמקם אותה באחת מפינות החדר או על יד קיר עם מקור חשמל. באיור הבא ניתן לראות את חיישן ה-LiDAR ואת מעמד ה-LiDAR המורכב משני חלקים המחוברים באמצעות ארבעה ברגי M4X30 ואשר מידותיהם מתאימים ספציפית לחיישן בו נעשה שימוש בפרויקט זה, ולכן יש להתאים את המידות באם נרצה להחליף את חיישן ה-LiDAR הנוכחי בחיישן LiDAR אחר. החלק העליון תופס את חיישן ה-LiDAR במקומו, והחלק התחתון הינו כיסוי למפצל החשמל ולשנאי המתח הן של המחשב והן של חיישן ה-LiDAR. את מידות התכנן למתקן מערכת החישה ניתן לראות בנספחים.



איור 5.3: מודל חיישן ה-LiDAR ומעמד ה-LiDAR ב-SOLIDWORK



איור 5.4: חיישן ה-LiDAR ומעמד ה-LiDAR המודפס

## 6. תוספות לאלגוריתם הולכי הרגל הראשוני

פרויקט זה עושה שימוש באלגוריתם קיים אשר מבוסס על האלגוריתם לזיהוי הולכי רגל כפי שתואר בפרק 4. פרק זה דן בתרומה המעשית שלנו לפרויקט ובאימות התכן הרעיוני המוצג באיור 5.1. דהיינו, שערכם הנומרי של הפרמטרים החשובים לניטור הקשיש משקפים את המציאות.

### 6.1. אלגוריתם ראשוני לחישוב הפרמטרים

בפרק זה יוצג האלגוריתם שלנו שנכתב בפרויקט זה, ובו נעשה שימוש לצורך מדידת הפרמטרים המופיעים בתתי פרקים הבאים 6.2 ו-6.3, לניטור וזיהוי סיכונים לאורך זמן. אלגוריתם זה מהווה בסיס, אך אינו מייצג את מבנה האלגוריתם הסופי, אלא מהווה אימות ותוקף בלבד לכך שהאלגוריתם עובד וכי ערכם הנומרי של הפרמטרים המתקבלים אכן מייצגים את המציאות. תיקוף האלגוריתם נעשה באמצעות ניסוי. באיור 6.1 ניתן לראות את האלגוריתם הראשוני בו נעשה שימוש.

```
#!/usr/bin/env python
from timeit import default_timer as timer
from std_msgs.msg import String
from visualization_msgs.msg import MarkerArray
from datetime import date
import time
import rospy
import numpy as np
import math

todays_date = date.today()
positionx = []
positiony = []
positionz = []
avgpositionx = []
avgpositiony = []
avgpositionz = []
t_start=time.time() #to count time for person in room and subtract time when not in room
#(time "stops" if not in room)

t1=0 #time reference
t_startmonth=time.time() #to reset time each month and print value of time in room
month = todays_date.month #will be used in callback to save current month
MRT = [] #Monthly Room Time
distance = 0

def callback(data):
    global t_start,t1, t_startmonth, month, distance
    if(len(data.markers)>1):
        positionx.append(data.markers[1].pose.position.x)
        positiony.append(data.markers[1].pose.position.y)
        positionz.append(data.markers[1].pose.position.z)
        if len(positionx) > 25: # n=25
            avgpositionx.append(np.sum(positionx[-25:])/25) #SMA
            avgpositiony.append(np.sum(positiony[-25:])/25) #SMA
            avgpositionz.append(np.sum(positionz[-25:])/25) #SMA
        t1=time.time()-t_start
        distance = EuclideanDistance(avgpositionx,avgpositiony,distance)
        print("z is",avgpositionz[-1])
        print("distance is",distance)
        print("The total time in the room is:",time.time()-t_start, "seconds.")
        print("len of markers is ",len(data.markers))
    else:
        t_start=time.time()-t1 #when person not in room
        if(time.time()-t_startmonth < 2629744.1005 and time.time()-t_startmonth > 2629743.633):
            print("The total time in the room in ", month, "is: ", time.time()-t_start, "seconds.")
            t_startmonth=time.time()-t1 #resetting month time
            month = todays_date.month #saving current month
            MRT.append(time.time()-t_start)

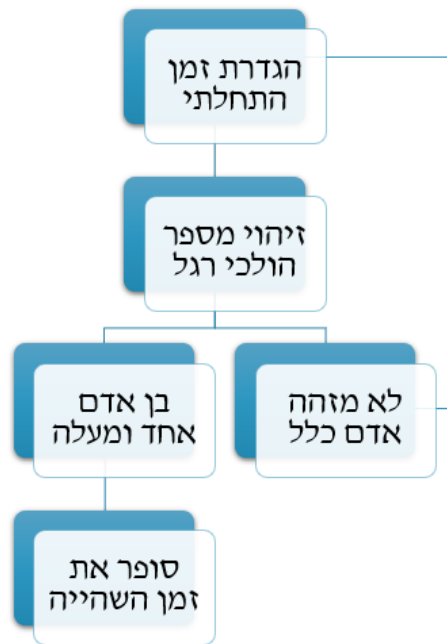
def EuclideanDistance(x,y,distance):
    addition = 0
    num1=x[-1]
    num2=x[-2]
    num3=y[-1]
    num4=y[-2]
    addition = math.sqrt(pow(num1-num2,2)+pow(num3-num4,2))
    if (addition > 0.008 and addition < 2): # HPF
        distance += addition # HPF
    return distance

def main():
    rospy.init_node('main', anonymous=True)
    rospy.Subscriber('hdl_people_tracking_nodelet/markers',MarkerArray, callback)
    # spin() simply keeps python from exiting until this node is stopped
    rospy.spin()
if __name__ == '__main__':
    main()
```

## איור 6.1: אלגוריתם ראשוני לחישוב הפרמטרים

## 6.2. זמן שהייה בחדר

זמן שהייה בחדר הינו אחד מהפרמטרים החשובים לניטור וזיהוי סיכונים אצל קשישים. ההיגיון אומר שקשיש פעיל יותר, ישהה פחות זמן בביתו ויבלה יותר זמן בפעילויות חברתיות, תחביבים, חדר כושר, בריכה ועוד. מנגד, קשיש השוהה בביתו זמן רב, יכול להוות סממן לקושי, התעניפות ו/או חרדה. את זמן שהייה בחדר ניתן לסווג לשני סוגים; פעיל ולא פעיל. כאשר מערכת החישה מציגה כי מיקומו של הקשיש אינו משתנה עד כדי רעש, ניתן לסווג זאת בתור זמן שהייה לא פעיל, היכול להעיד על מצוקה וצורך בעזרה מיידית, ולהפך.



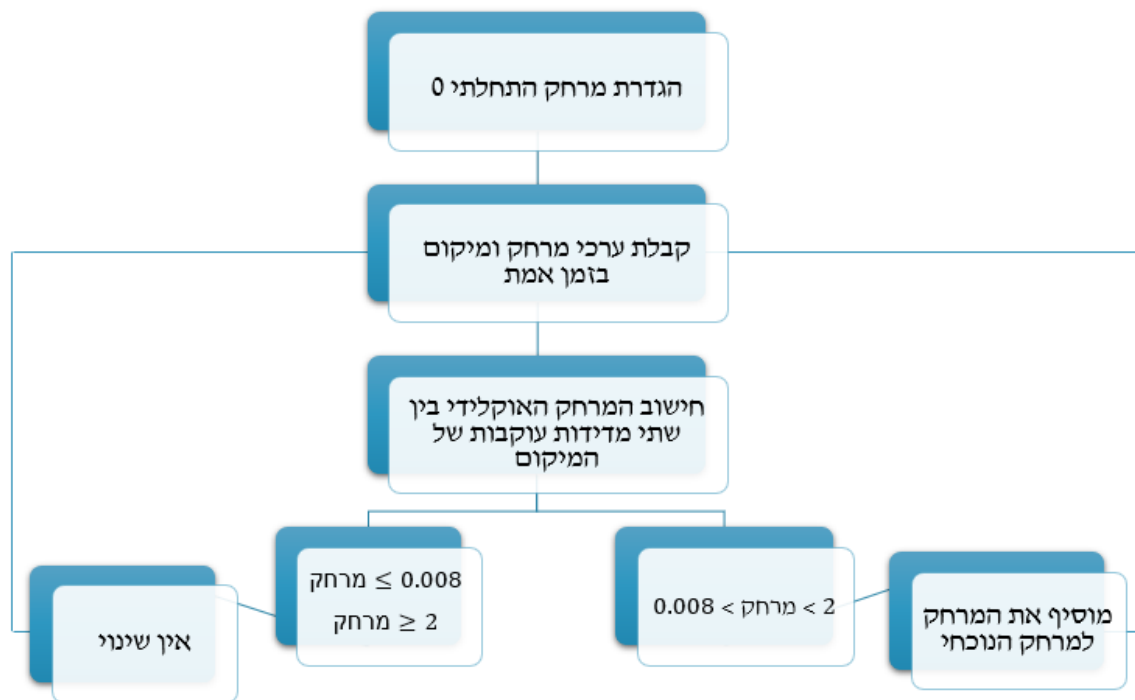
איור 6.2: אלגוריתם לחישוב זמן השהייה בחדר

### 6.3. מרחק אוקלידי

מרחק הליכתו של הקשיש הינו פרמטר נוסף אשר באמצעותו נוכל לקבל מידע אודות מצבו הפיזי של הקשיש והאם הוא במגמת התדרדרות. זמן שהייה פעיל בחדר, מהירות ותאוצה הינם נגזרות של פרמטר זה, ולכן יש לו חשיבות רבה. חישוב המרחק האוקלידי מבוצע על פי המשוואה הבאה:

$$d_{Euclidean}(x_i, y_i) = \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2} \quad (6.1)$$

כאשר  $x_i$  ו- $y_i$  הן קואורדינטות האשכול, ביחס ל-LiDAR, המסווג כהולך רגל בזמן  $t_i$  ו- $i=1,2,\dots,n$ . בפרק 4.2. הוצגו הבעיות העיקריות בחישוב פרמטר זה והן טופלו על ידי מסננים די פשוטים ואינטואיטיביים מסוג HPF ו-SMA. באיור הבא ניתן לראות את האלגוריתמיקה מאחורי חישוב המרחק האוקלידי.



איור 6.3: אלגוריתם לחישוב המרחק האוקלידי

#### 6.4. פונקציה לזיהוי והסרה של מדידות חריגות

על מנת לסווג כמעט נפילות ונפילות, הוצע לעשות שימוש בפונקציה להסרת מדידות חריגות שכן בעת כמעט נפילה ואו נפילה, ישנה קפיצה משמעותית בערכי המיקום והמהירות של הקשיש. לשם זיהוי והסרה של קפיצות מסוג זה, כתבנו פונקציה המזהה מדידות חריגות, מחליפה את המדידות הללו בערך NaN ולאחר מכן מסירה את כל ערכי ה-NaN מהמערך. בשלב הראשון הפונקציה מסירה את המדידות ה-"רחוקות" על ידי שיטת טווח בין-רבעוני (IQR method). בשלב השני, בכדי להסיר ערכי ביניים ללא שימוש בערך סף, כלומר בצורה כללית אשר תתאים לכל מאגר מידע שהוא, הפונקציה תגדיר מערך חדש שערכיו הינם חיסור של האיברים העוקבים במערך המקורי ועל ידי ציון התקן (Z-score), נוכל לגלות לאיזה אינדקס במערך המקורי מתקבלת מדידה חריגה, שכן בווטור חיסור האיברים העוקבים יתקבלו ערכים רחוקים מהממוצע ומסטיית התקן באם ישנן מדידות חריגות. דוגמה למערך בו ישנן מדידות חריגות:


$$u = [20.1, 21.2, \dots, 60.2, 61.2, 20.2, 62.5, 500]$$

כאשר הערכים 20.2 ו-500 מוגדרים כמדידות חריגות (outliers). כעת נציג דוגמה של מדידות פיקטיביות עבור מרחק כפונקציה של הזמן בהן ישנן מדידות חריגות, אשר הוסרו על ידי הפונקציה שנכתבה בפרויקט זה. את המדידות הפיקטיביות הפונקציה קוראת מקובץ csv ובאזור הבא ניתן לראות חלק מהמדידות הפיקטיביות כאשר אחת מהן הינה מדידה חריגה ומסומנת על ידי משבצת אדומה. תחילה הפעלנו את הפונקציה עם מרחקים חריגים של מרחק אפס בלבד, ולאחר מכן עם ערכים רחוקים וערכי ביניים לא פיסיקליים.

	Distance	Time
1	3.32779	0
2	3.38362	0.06
3	3.29279	0.12
4	5.44333	0.18
5	7.00672	0.24
6	8.60573	0.3
7	8.46184	0.36
8	9.65502	0.42
9	13.1217	0.48
10	14.57645	0.54
11	15.97396	0.6
12	17.64921	0.66
13	19.0493	0.72
14	20.32754	0.78
15	21.85652	0.84
16	23.56282	0.9
17	25.40708	0.96
18	26.64049	1.02
19	27.34615	1.08
20	29.62972	1.14
21	31.04235	1.2
22	0	1.26
23	33.25032	1.32
24	35.44196	1.38

**איור 6.4: מדידות פיקטיביות עבור מרחק כפונקציה של הזמן בהן ישנן מדידות חריגות עם מרחק אפס**

מקובץ זה יצרנו גרף של המרחקים כתלות בזמן לפני ואחרי הפעלת הפונקציה. באיור הבא ניתן לראות גרף של המרחקים כתלות בזמן לפני הפעלת הפונקציה.




**איור 6.5: גרף של המרחקים כתלות בזמן לפני הפעלת הפונקציה**

ניתן לראות בבירור את המדידות החריגות בגרף הנ"ל.

לאחר הפעלת הפונקציה, הגרף החדש של המרחקים כתלות בזמן מוצג באיור 6.6.





איור 6.6: גרף של המרחקים כתלות בזמן אחרי הפעלת הפונקציה

התקבל גרף זהה לגרף שבאיור 6.6 גם לאחר סיבוך המדידות הפיקטיביות על ידי החלפה של המדידות החריגות השוות למרחק אפס בערכים רחוקים וערכי ביניים לא פסיקליים, כפי שמתואר באיור הבא:

	Distance	Time
1	64.66063	2.64
2	20.3	2.7
3	65.84139	2.76
4	68.87962	2.82
5	69.32243	2.88
6	69.83684	2.94
7	70.26746	3
8	73.49286	3.06
9	73.82099	3.12
10	74.20438	3.18
11	74.58288	3.24
12	78.59796	3.3
13	78.82649	3.36
14	79.05191	3.42
15	79.25531	3.48
16	80.65126	3.54
17	80.82208	3.6
18	80.9903	3.66
19	81.1843	3.72
20	85.07025	3.78
21	85.10337	3.84
22	85.14135	3.9
23	85.52011	3.96
24	236	4.02

איור 6.7: מדידות פיקטיביות עבור מרחק כפונקציה של הזמן בהן ישנן מדידות חריגות

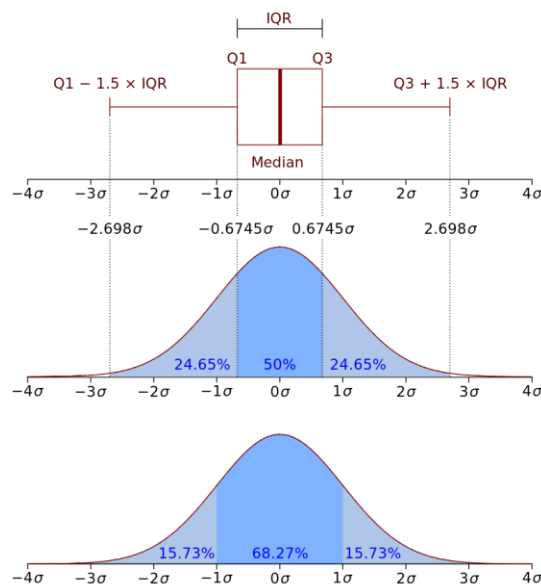
#### 6.4.1. שיטת טווח בין-רבעוני להסרת מדידות חריגות

הטווח הבין-רבעוני (IQR) הוא מדד לפיזור סטטיסטי המוגדר כהבדל בין האחוזון ה-75 וה-25 של הנתונים. ה-IQR מתאר את ה-50% מהערכים האמצעיים כשהם מסודרים מהנמוך לגבוה ביותר. כדי למצוא את הטווח הבין-רבעוני (IQR), יש למצוא תחילה את החציון (הערך האמצעי) של החצי התחתון והעליון של הנתונים. ערכים אלו הם רבעון 1 ( $Q_1$ ) ורבעון 3 ( $Q_3$ ). ה-IQR הוא ההבדל בין  $Q_3$  ל- $Q_1$ . כדי לחשב את ה-IQR, מערך הנתונים מחולק לרבעונים, או לארבעה חלקים זוגיים בסדר דירוג באמצעות אינטרפולציה ליניארית. רבעונים אלה מסומנים באופן הבא:  $Q_1$  (הנקרא הרבעון התחתון),  $Q_2$  (החציון) ו- $Q_3$  (נקרא הרבעון העליון). להלן תרשים קופסה עם טווח בין-רבעוני ופונקציית צפיפות-הסתברות (pdf) של אוכלוסיית  $N(0, \sigma^2)$  נורמאלית.

$Q_1$  - רבעון ראשון - ערך שעד אליו 1/4 (25% מהשכיחויות) ומעליו 3/4 (75%) מהמקרים.

$Q_2$  - רבעון שני - החציון, הערך ש-1/2 (50% מהשכיחויות) מהמקרים קטנים/שווים לו ו-1/2 גדולים/שווים לו.

$Q_3$  - רבעון שלישי - הערך שמתחתיו 3/4 מההתפלגות ומעליו 1/4 ממנה.



איור 6.8: תרשים קופסה עם טווח בין-רבעוני ופונקציית צפיפות-הסתברות

המדידות החריגות מוגדרות כמדידות שערכיהן מתחת לחסם התחתון לפי החישוב-

$$Q_1 - 1.5 \text{ IQR}$$

או מעל לחסם העליון לפי החישוב-

$$Q_3 + 1.5 \text{ IQR}$$

#### 6.4.2. שיטת ציון התקן להסרת מדידות חריגות

ציון תקן מבטא את המרחק של תצפית מן התוחלת במונחי יחידות סטיית תקן, כאשר ציון תקן חיובי מצביע על תצפית הגבוהה בערכה המספרי מתוחלת האוכלוסייה, וציון תקן שלילי מצביע על תצפית הנמוכה בערכה המספרי מתוחלת האוכלוסייה. בשלב זה הפונקציה מחשבת את ציון התקן עבור כל מדידה כאשר כל ציון תקן הגדול מ-3 או אשר קטן מ-3 נחשב לחורג. מספר זה הינו כלל אצבע אמפירי האומר שכמעט כל הנתונים (99.7%) צריכים להיות בטווח של שלוש סטיות תקן מהממוצע.

#### 6.4.3. קוד הפונקציה להסרת מדידות חריגות

בתת פרק זה תוצג הפונקציה להסרת המדידות החריגות. באיור 6.9 ניתן לראות את הקריאה לפונקציית הסרת המדידות החריגות 'remove\_outliers' אשר מקבלת מבנה נתונים בעל תווית דו-ממדית עם עמודות מסוגים שונים בשם DataFrame, באיור 6.10 ניתן לראות את קוד הפונקציה ובאיור 6.11 את אופן פעולת האלגוריתם.

```
positionx.append(data.markers[1].pose.position.x)
positiony.append(data.markers[1].pose.position.y)
positionz.append(data.markers[1].pose.position.z)
#Setting up DataFrames
df1 = pd.DataFrame({'distance_col': positionx[-25:]})
df2 = pd.DataFrame({'distance_col': positiony[-25:]})
df3 = pd.DataFrame({'distance_col': positionz[-25:]})
#Removing outliers from the coordinates x,y,z
filtered_posx = remove_outliers(df1)
filtered_posy = remove_outliers(df2)
filtered_posz = remove_outliers(df3)
```

איור 6.9: הקריאה לפונקציית הסרת המדידות החריגות

```
def remove_outliers(df):
    # First we will filter "far" outliers using IQR method. Secondly, using Z-score method, we will filter
    # abnormal measurements e.g. in the following vector; u = [60.2, 61.2, 20.2, 62.9, ...]
    # the measurement u[2] = 20.2 is considered abnormal.

    # 'nan' outliers out-side of the lower/upper bound
    for j in ['distance_col']:
        q_75, q_25 = np.percentile(df.loc[:, j], [75, 25])
        inter_qr = q_75 - q_25
        maxima = q_75 + (1.5 * inter_qr) # upper-bound
        minima = q_25 - (1.5 * inter_qr) #s lower-bound
        df.loc[df[j] < minima, j] = np.nan
        df.loc[df[j] > maxima, j] = np.nan
        # null_counter = df.distance_col.isnull().sum() #test
        df_n = df.dropna(axis=0) # Removing nans

    # Creating a new array of the differences i.e. distance_col [j+1] - distance_col [j]
    # and then using distance_vector = distance_M[-25:-1] standard score we shall define the outliers.
    d = np.array(df_n['distance_col'])
    d_diff = np.diff(d)
    z = stats.zscore(d_diff)
    threshold = 3 # Standard deviation
    # Position of the outlier
    outlier_pos = np.where(z > threshold)
    outlier = d[outlier_pos]
    for j in ['distance_col']:
        for k in range(0, len(outlier)):
            df.loc[df[j] == outlier[k], j] = np.nan
    df = df.dropna(axis=0) # Removing nans
    d_n = np.array(df['distance_col'])
    return d_n
```

איור 6.10: קוד הפונקציה להסרת המדידות החריגות



איור 6.11: אלגוריתם פעולת הפונקציה לזיהוי מדידות חריגות

## 6.5. פלט נתונים למשתמש

על מנת לנסות ליצור שיפור באורח חייהם של הקשישים בעזרת תוכניות התערבות קליניות מתאימות, החיישן יבצע ניטור ארוך טווח באופן כזה שיוכל לזהות את המשתמש ולעקוב אחר יציבותו, כך שאפשר יהיה לזהות התדרדרות בשיווי המשקל ואף נפילה או "כמעט נפילה" אצל המשתמש.

בתום תקופת זמן מוגדרת (למשל חודש), המשתמש יוכל לראות באופן מפורט את נתוני המעקב אודות יציבותו בדו"ח המציג את המרחק המצטבר שהוא צעד, מהירותו הממוצעת, כמות המעידות שהיו לו, וזמן מנוחה בחדר. איור 6.12 מציג קוד להדפסת הנתונים.

```
# Monthly graphs and data
# t1=time.time()-t_start
# t_startmonth=time.time()
# distance_month = []
# MRT = []
# distance = EuclideanDistance(avgpositionx,avgpositiony,distance)
if(time.time()-t_startmonth < 2629744.1005 and time.time()-t_startmonth > 2629743.633): # avg time each month
    month = todays_date.month # saving current month
    MRT.append(time.time()-t_start) # monthly room time
    distance_month.append(distance) # monthly room distance
    if len(distance_month) > 1:
        monthly_distance = distance_month[-1] - distance_month[-2]
    else:
        monthly_distance = distance_month[-1]
    print("The total distance traveled in month", month, "is:", monthly_distance)
    print("The average velocity in month", month, "is:", np.mean(velocity_M))
    print("The total time in the room in month", month, "is: ", MRT[-1], "seconds.")
    time_startmonth = time.time() # resetting month time to recount the time until next month prints

else: #if(len(data.markers) <= 1)
    t_start=time.time()-t1 #when person not in room
```

איור 6.12: קוד להדפסת הנתונים

## 7. אימות עקרונות האלגוריתם

### 7.1. אימות חישוב המרחק האוקלידי באמצעות האלגוריתם הראשוני

בפרק זה מוצג אימות ניסויי לחישוב המרחק האוקלידי באמצעות האלגוריתם הראשוני לחישוב הפרמטרים החשובים לניטור וזיהוי סיכונים. בניסוי זה, נמדד המרחק האוקלידי אותו עובר הנבדק בהשוואה למרחק שנמדד על ידי החיישן.

איור 7.1 מציג את תוצאות הניסוי בטרמינל על יד המחשה ויזואלית בכלי Rviz, בו ניתן לראות את זמן השהייה באזור המדגם במהלך כל רגע נתון, ואת המרחק אותו הלך הנבדק בפרק זמן זה. המרחק שחושב על ידי האלגוריתם הינו:

$$d_{Euclidean_{calculated}} = 2.9918 [m]$$

```


('distance is', 2.936370411166161)
('velocity is', 3.3006676043487615)
('The total time in the room is:', 18.21979308128357, 'seconds.')
('len of markers is ', 2)
('velocity_z is', -2.4021975800043163)
('distance_z is', -0.96033960639971339)
('distance is', 2.9639688846843653)
('velocity is', 3.404599643273498)
('The total time in the room is:', 18.311681032180786, 'seconds.')
('len of markers is ', 2)
('velocity_z is', -2.5632167508138264)
('distance is', 2.991844269632825)
('The total time in the room is:', 18.435966968536377, 'seconds.')
('len of markers is ', 2)

```

איור 7.1: תוצאות הניסוי לאימות אלגוריתם חישוב המרחק האוקלידי כפי שמופיעות בטרמינל

באיור 7.2 ניתן לראות את מרחק המסלול האמיתי אשר נמדד באמצעות מטר, שבמהלך הניסוי הנבדקת הלכה, כאשר המרחק שנמדד באמצעות המטר הינו:

$$d_{Euclidean_{measured}} \approx 3 [m]$$



איור 7.2: מדידת מרחק המסלול בניסוי לאימות אלגוריתם המחשב את המרחק האוקלידי

חשוב לציין כי ניסוי זה נעשה מספר פעמים ובמהירויות הליכה שונות כשבכל פעם התקבלו תוצאות די טובות. במהירויות הליכה גבוהות, דיוק חישוב המרחק האוקלידי על ידי האלגוריתם הראשוני הולך ופוחת כמצופה מעצם הוספת מסנן ממוצע נע לקואורדינטות הנבדק ביחס למערכת ה-LiDAR. מכיוון שפרויקט זה עוסק בפיתוח מוצר לניטור קשישים, אין בעיה בכך.

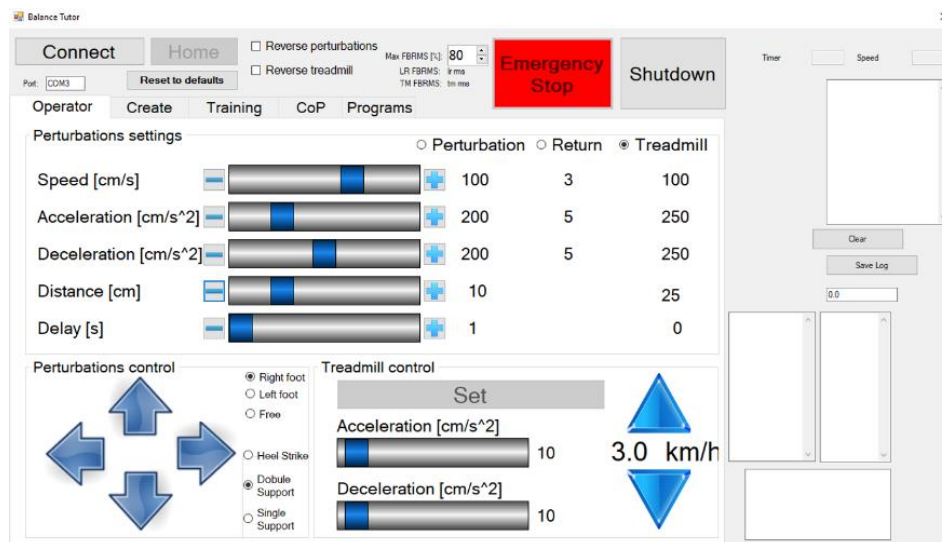
## 7.2. תיקוף האלגוריתם באמצעות ניסוי במערכות ה-Vicon וה-BaMPer

מטרות הניסוי הן הוצאת נתונים באמצעות מערכות ה-Vicon וה-BaMPer שנמצאות במעבדתו של פרופסור איציק מלצר, בפקולטה למדעי הבריאות, על מנת לוודא שניתן לזהות נפילות וכמעט נפילות על ידי מיקום מרכז המסה בציר האנכי כתלות בזמן, זאת על ידי השוואה בין המדידות שהתקבלו במערכת ה-VICON (state-of-the-art) לבין המדידות שהתקבלו בLiDAR לשם תיקוף האלגוריתם.

### 7.2.1. מהלך הניסוי

בניסוי זה נבדקה ההשערה שאכן קיים קשר בין מיקום מרכז המסה בציר האנכי לבין זיהוי נכון של כמעט-נפילות ואף נפילות.

תחילה, נערך כיוול למערכות והתאמתן לניסוי הנוכחי ולתנאי התאורה שבמעבדה. בשלב זה הוטען הפרוטוקול והוגדרו הנתונים המתאימים בתוכנת הבקרה של ה-BaMPer כפי שניתן לראות בתמונה הבאה:




איור 7.3: הגדרת נתונים בתוכנת ה-Balance Tutor

לאחר מכן, הולבש הנבדק בחליפה מיועדת שאליה חוברו מרקרים אשר מזוהים על ידי 16 מצלמות אינפרה-אדום (להפנות למידע על המערכת). לאחר מכן, אובטח הנבדק באמצעות רתמה לתקרה כאשר הוא עומד על ה-BaMPer. במקביל הופעלה תוכנת ה-Vicon Nexus כך שתזהה את הנבדק (את המרקרים שעליו) כשהוא עומד בעמידת מוצא שבה למצלמות יש את הראות הכי טובה של המרקרים, כך שאפשר להתחיל בניסוי.

באיור הבא ניתן לראות את סכמת מערכת הניסוי שבמעבדתו של פרופסור מלצר כאשר ציר z הינו הציר האנכי.





**איור 7.4: סכמת מערכת הניסוי**

במהלך הניסוי הנבדק צועד על BaMPer והפרוטוקול רץ, כאשר מגיעה פרטורבציה היא מזיזה את המערכת כך שהנבדק מועד או מאבד יציבות. בו בזמן, מערכת ה-Vicon מתעדת כל תזוזה שלו בעזרת המרקרים המודבקים עליו והמצלמות, כך שישנו סרטון של הניסוי בו נראה הנבדק לפי קווי הגוף שנוצרים מהמרקרים.


#### **7.2.2. תוצאות הניסוי**

בתום הניסוי התקבל קובץ של תנועת BaMPer בחסות הפרוטוקול המתאים, ובנוסף חושבו מיקום ומהירות מרכז המסה בשלושת הצירים  $x$ ,  $y$ ,  $z$  בכל פריים נתון שמתבצע על ידי תוכנת Vicon Nexus בעת העברת הנתונים לקובץ csv.


בגרפים שבאיורים 7.5 ו- 7.6 ניתן לראות את תוצאות הניסוי הגולמיות, כלומר את מיקום מרכז המסה ומהירות מרכז המסה בציר האנכי (ציר  $z$ ) כתלות בפריים. בנוסף, באיור 7.7 ניתן לראות את הנבדק על גבי הסימולציה בפריימים שונים; רגע לפני ההפרעה ורגע אחרי ההפרעה בהתאם לפריימים בהן התרחשו.




מתוך הגרפים בהשוואה לתנועה האמיתית של הנבדק, אפשר לראות בבירור שאכן קיימת התאמה בין הקפיצה הגדולה שמתרחשת בציר  $Z$  לבין מספר הפריים בו ניתן לראות שהנבדק אכן מעד בסרטון.



**איור 7.5: גרף מיקום תלות פריים**



**איור 7.6: גרף מהירות תלות פריים**



איור 7.7: הנבדק על גבי הסימולציה בפריימים שונים של הניסוי

### 7.3 עריכת הניסוי במערכת ה-LiDAR

לצורך בדיקת ביצוע זיהוי של נפילה וכמעט נפילה על ידי האלגוריתם דרך חיישן ה-LiDAR עצמו, יש לוודא שהוא אכן מזהה שינוי משמעותי של ירידת מרכז המסה לאורך ציר Z (הגובה מהרצפה לתקרה), או קפיצה גדולה במהירות האדם. שינוי כזה מעיד על כך שמרכז המסה של האדם ירד במהירות לא סטנדרטית לגובה לא סביר, משמע, מקרה חריג שיש לזהות.

#### 7.3.1 מהלך הניסוי

מכשיר ה-LiDAR הוצב במעבדה של פרופסור איציק מלצר, מול מערכת ה-BaMPer, כך שיזהה את הנבדק אשר עומד על הבמה. לאחר שהנבדק אובטח על-ידי הרתמה, החל הניסוי ומערכת ה-BaMPer הופעלה לפי הפרוטוקול\* בזמן שחיישן ה-LiDAR מופעל ומזהה את תנועת הנבדק.

#### 7.3.2 תוצאות הניסוי

בתום הניסוי, נפלט קובץ csv באמצעות הפונקציות המצורפות באיור 7.8, אל המחשב המחובר ל-LiDAR אשר מכיל נתונים על מיקום ומהירות הנבדק בכל שניה מתחילת הניסוי ועד סופו. מקובץ זה ניתן להפיק גרפים המראים באופן ויזואלי את החריגות במיקום ובמהירות הנבדק, כך שניתן להסיק שבזמן חריגות אלה אירעה פרטורבציה במערכת ה-BaMPer שגרמה למעידה של הנבדק.

```
def main():
    with open('test.csv', 'w') as csvfile:
        fieldnames = ['time', 'distance_z', 'velocity_z', 'outliers']
        writer = csv.DictWriter(csvfile, fieldnames=fieldnames)
        writer.writeheader()
    rospy.init_node('main', anonymous=True)
    rospy.Subscriber('hdl_people_tracking_nodelet/markers', MarkerArray, callback)
    # spin() simply keeps python from exiting until this node is stopped
    rospy.spin()
if __name__ == '__main__':
    main()

with open('test.csv', 'a') as csvfile:
    fieldnames = ['time', 'distance_z', 'velocity_z', 'outliers']
    writer = csv.DictWriter(csvfile, fieldnames=fieldnames)
    writer.writerow({'time': time.time()-t_start, 'distance_z': distance_z, 'velocity_z': velocity_z, 'outliers': outliers})
```

#### איור 7.8: הפונקציה שמדפיסה את קובץ csv

כאשר מצב הכתיבה ('w') יוצר קובץ חדש ומצב ('a') append משמש להוספת הנתונים בסוף הקובץ אם הקובץ כבר קיים (אם הקובץ כבר קיים מצב כתיבה מחליף אותו).

\*הפרוטוקול הוא קובץ מוכן שנכתב מראש על ידי פרופסור איציק מלצר, אשר ניתן לטעינה בתוכנת ה-Balance tuner ומספק למערכת הנחיות קבועות לעיתוי, כיוון ועוצמת הפרטורבציות.

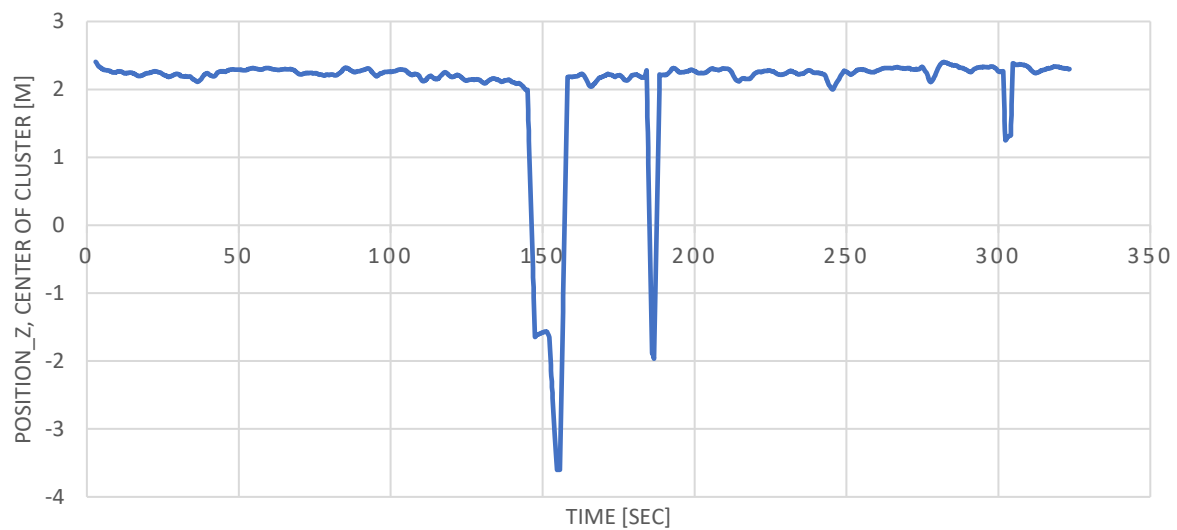
באיור 7.9 ניתן לראות את הפרוטוקול עימו נערך הניסוי.

```
3,25,25,30
60,1,11,35,35,3,3,3,3,3,1,1
75,2,11,35,35,3,3,3,3,3,1,1
90,1,22,70,70,6,3,3,3,3,1,1
105,2,22,70,70,6,3,3,3,3,1,1
120,1,44,150,150,9,3,3,3,3,1,1
140,2,44,150,150,9,3,3,3,3,1,1
160,1,66,200,200,12,3,3,3,3,1,1
180,2,66,200,200,12,3,3,3,3,1,1
210,1,88,250,250,15,3,3,3,3,1,1
240,2,88,250,250,15,3,3,3,3,1,1
270,1,120,300,300,18,3,3,3,3,1,1
300,2,120,300,300,18,3,3,3,3,1,1
```


#### איור 7.9: צילום מקובץ txt של פרוטוקול הניסוי

כאשר המספר הראשון משמאל בכל שורה מייצג את השנייה בה מתרחשת הפרטורבציה, המספר השני הוא כיוון הפרטורבציה: 1-ימין, 2-שמאל. המספרים השלישי, הרביעי והחמישי הם מהירות, תאוצה ותאוצה של הפרטורבציות בהתאמה. המספר השישי הוא מרחק הפרטורבציה בס"מ, כלומר המרחק של תזוזת הבמה, והמספר השביעי מראה כמה זמן ייקח לבמה לחזור למקומה הטבעי (בשניות).

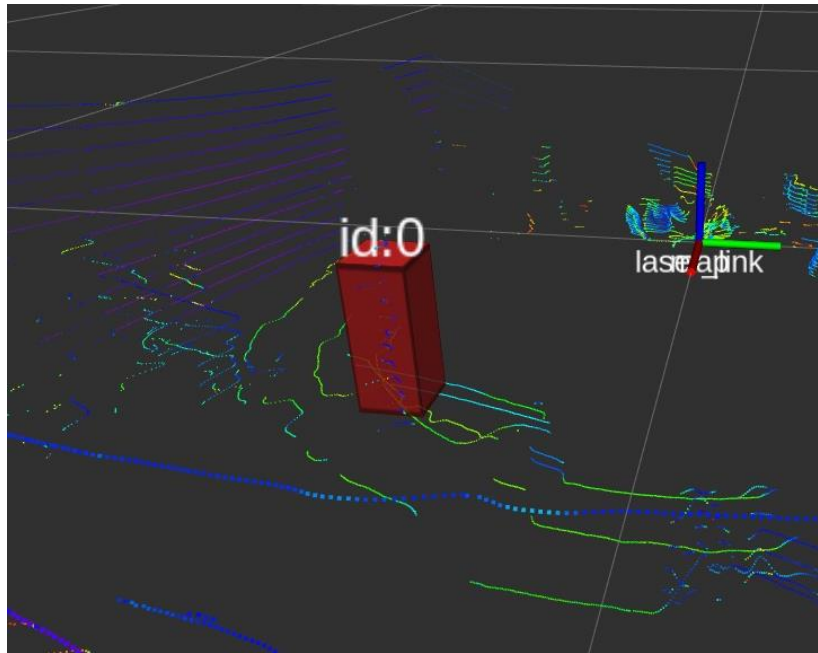
ממספר ניסויים שנערכו על נבדקים שונים, ניתן לשים לב (איורים 7.10 ו-7.11) שהחריגות אצל רוב הנבדקים התרחשו באותן שניות לערך. בהשוואה לפרוטוקול הניסוי, אשר בו מצוין באיזו שנייה אירעה פרטורבציה במערכת, ניתן לראות כי החריגות אכן התרחשו בזמנים בהם אירעה פרטורבציה שגרמה למעידה של הנבדק.



**איור 7.10: מרכז האשכול על פי האלגוריתם**




**איור 7.11: מהירות מרכז האשכול על פי האלגוריתם**




איור 7.12: זיהוי הנבדק שעומד על BaMPer על ידי חיישן ה-LiDAR

#### 7.4. השוואה בין תוצאות ה-LiDAR וה-Vicon

לצורך השוואה בין שתי המערכות נערך ניסוי חדש כך ששתי המערכות, מערכת ה-Vicon ומערכת ה-LiDAR הופעלו במקביל על אותו הנבדק. הניסוי זהה לחלוטין לניסויים שפורטו בנפרד עבור כל מערכת בפרקים הקודמים. באיורים 7.13 ו-7.14 ניתן לראות את תוצאות הניסוי הגולמיות כפי שהתקבלו ממערכת ה-Vicon.




איור 7.13: מיקום מרכז המסה בציר האנכי כפונקציה של ה-Frame במערכת ה-Vicon




**איור 7.14: מהירות מרכז המסה בציר האנכי כפונקציה של ה-Frame במערכת ה-Vicon**

נמיר את הפריימים (Frames) לשניות על ידי חלוקה ב-120, מכיוון שמערכת ה-Vicon עובדת בתדירות של 120 הרץ.




**איור 7.15: מיקום מרכז המסה בציר האנכי כפונקציה של הזמן במערכת ה-Vicon**




**איור 7.16: מהירות מרכז המסה בציר האנכי כפונקציה של הזמן במערכת ה-Vicon**

על פי ניתוח גרפי בלבד של תוצאות הניסוי של במערכת ה-Vicon, זוהו שבע כמעט נפילות בשניות 140, 160, 180, 210 ו-240, 270 ו-300 בהתאמה לזמנים בהם יש פרטורבציות בפרוטוקול הניסוי.

באיורים 7.17 ו-7.18 ניתן לראות את תוצאות הניסוי הגולמיות כפי שהתקבלו ממערכת ה-LiDAR.



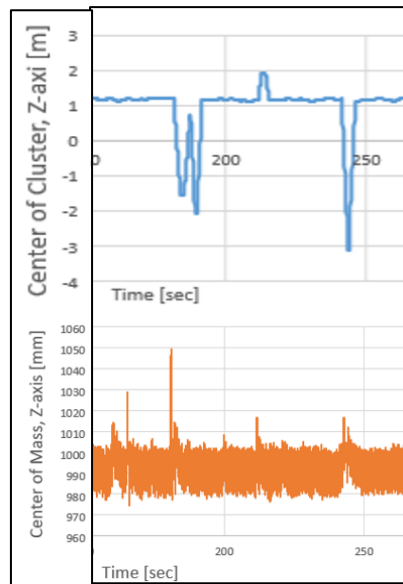
**איור 7.17: מיקום מרכז האשכול בציר האנכי כפונקציה של הזמן במערכת ה-LiDAR**



**איור 7.18: מהירות מרכז האשכול בציר האנכי כפונקציה של הזמן במערכת ה-LiDAR**

על פי ניתוח גרפי בלבד של תוצאות הניסוי במערכת ה-LiDAR, זוהו שלוש כמעט נפילות בשניות 180, 210 ו-240 בהתאמה לזמנים בהם יש פרטורבציות בפרוטוקול הניסוי.

באיור 7.19 ניתן לראות את חלקי הגרפים בהם נראית התאמה בניסויים, כאשר הגרף העליון הינו מיקום מרכז האשכול בציר האנכי כפונקציה של הזמן במערכת ה-LiDAR והגרף התחתון הינו מיקום מרכז המסה בציר האנכי כפונקציה של הזמן במערכת ה-Vicon.



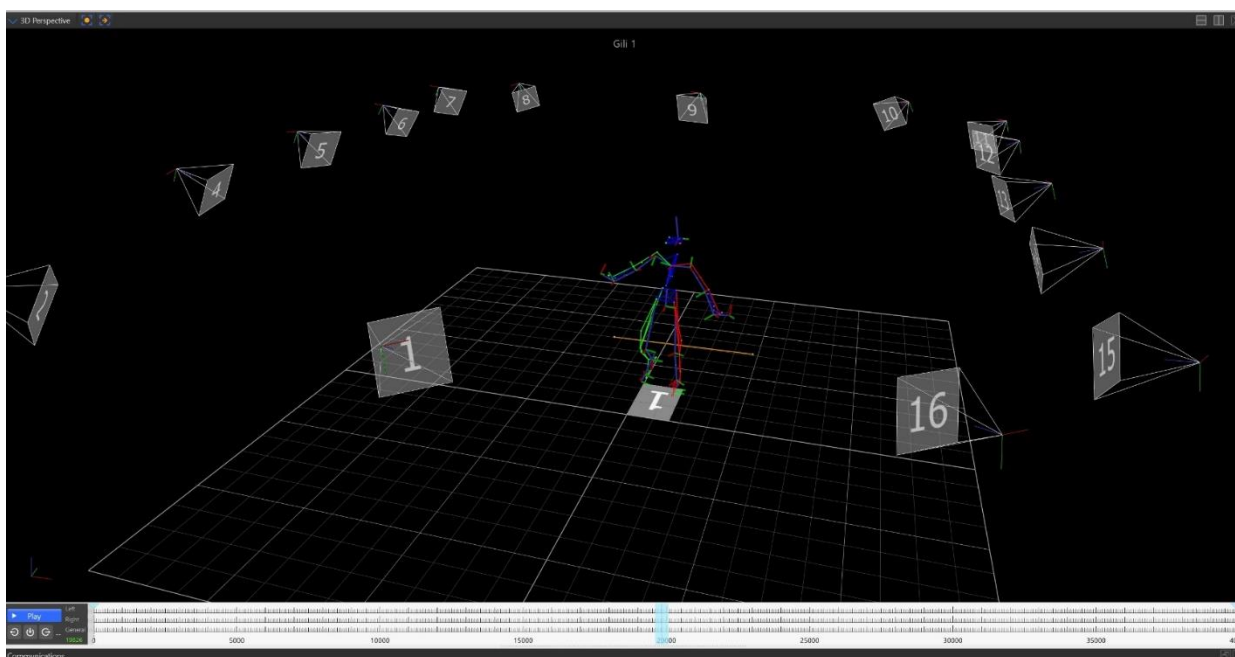
איור 7.19: חלקי הגרפים השונים לפי הזמן בהם נראית התאמה בניסויים

#### 7.4.1. מסקנות

על סמך ניתוח גרפי מתוצאות הניסוי הגולמיות בלבד, למערכת ה-LiDAR יש דיוק של 43% בהשוואה למערכת ה-Vicon אם מניחים שכל קפיצה פתאומית בגרפי המיקום ומהירות של מרכז המסה או האשכול מצביעה על כמעט נפילה. בפועל, לא כל פרטורבציה בה הנבדק זז גרמה לנפילה או לכמעט נפילה. כדי להחליט מתי אכן התרחשה כמעט נפילה, ניתן להיעזר בתוכנת ה-Vicon Nexus על ידי הפעלת סימולציית הניסוי פריים אחר פריים וכך לראות על פי תנועת הנבדק האם הוא כמעט נפל או לא. מניתוח הסימולציה (ראה איור 7.19) נראה כי בשנייה 160, תגובת הנבדק לפרטורבציה הייתה מהירה מאוד וכמעט לא השפיעה על הליכתו, להבדיל מהפרטורבציות השונות בהן אירעו קפיצות משמעותיות בגרפי המיקום והמהירות. מכאן שלמערכת ה-LiDAR דיוק של 50% בניסוי זה בלבד ויש לבצע מספר רב של ניסויים כדי להגיע לדיוק האמיתי, שיהיה ממוצע של הדיוקים השונים מכל ניסוי.

ניתן לראות באיור 7.17 כי ישנן קפיצות קטנות אך שיפוע גדול יחסית, ואולי, על ידי נתונים נוספים יהיה ניתן להסיק מסקנות נוספות. בנוסף, הפרמטרים שהוגדרו עבור אלגוריתם זיהוי הולכי הרגל אינם אופטימליים ואולי תיתכן אפשרות לשפר את הדיוק על ידי שינוי נכון של פרמטרים אלו. לחילופין, ניתן לעשות שימוש בחיישן LiDAR בעל רזולוציה גבוהה יותר, או בחיישן ה-LiDAR עליו כבר נעשתה אופטימיזציה של הפרמטרים באלגוריתם של Kenji Koide, העושה שימוש בחיישן Velodyne HDL-32e. אפשרות נוספת הינה פיתוח אלגוריתם ייעודי לפרויקט זה אשר מזהה אנשים, כך שיתאים לחיישן ה-LiDAR בו נעשה שימוש בצורה אופטימלית, בדומה לאלגוריתם זיהוי הולכי הרגל של Kenji Koide.





איור 7.20: צילום מסך מתוך סימולציית הניסוי

## 8. הערכה כלכלית

מערכת החישה המוצעת בפרויקט זה מורכבת משני רכיבים עיקריים הכוללים מכשיר מדידה ומחשב. בטבלה הבאה יוצגו מחירי מוצרי המדף המהווים את החלקים העיקריים בפרויקט.

טבלה 8.1: מוצרי המדף והערכה כלכלית

עלות	יצרן	כמות	רכיב
₪5,250	Leishen Intelligent System	1	3D LiDAR
₪1,500-3,000	TBD	1	Computer
₪50	Prof. Amir Shapiro's laboratory	1	Stand/Packaging
₪36,000	-	600	שעות עבודה סטודנטים
₪1,500	-	10	שעות עבודה אחראי מעבדות
₪5,200	-	26	שעות עבודה מנחים
₪49,500-51,000	סה"כ		


לשם האומדן, הערכות לגבי העלויות הרפואיות של נפילות בקרב קשישים בארצות הברית, הכוללות שברים הקשורים לנפילה, אשר מהווים את החלק העיקרי בהתייקרות הטיפול, נאמדו לאחרונה ב-7 עד 10 מיליארד דולר בשנה. כ-90% מהעלויות הרפואיות הישירות של 5.2 מיליארד דולר ב-1986 היו מיוחסות לטיפול בבתי חולים ובבית אבות, 66 אחוזים מהאשפוזים ו-82 אחוזים מהאשפוזים הסיעודיים שנגמרו מנפילה כוללים שברים. יתרה מכך, נפילה היא בדרך כלל מקור לטראומה אצל קשישים, ועלולה לגרום למגבלות ונכות גם כתוצאה מהפחד מנפילה [28].

## 8.1 סקר צרכנים

על מנת לקבל תמונה רחבה יותר לדרישת המוצר, מחד גיסא בהיבט הכלכלי ומאידך גיסא בהיבט הצרכני, במסגרת התוכנית הכלכלית של הפרויקט נערכה שאילתה בדיור מוגן לגבי הצורך במוצר מהסוג המוצע בפרויקט, והאם תהיה מוכנות לשלם עבור מוצר זה. נוסף על כך, עקב ההיבט הצרכני נכללו בסקר גם ילדיהם של קשישים שענו אם הם מעוניינים במערכת בכדי להגן על הוריהם, ולא בהכרח הוצעה המערכת ישירות לקשישים עצמם.

להלן, תוצאות הסקר כאשר הוא חולק לשני סוגי צרכים: נמצא בדיור מוגן ועונה בשם עצמו ועונה בשם בן משפחה של מי שנמצא בדיור מוגן.


### 8.1.1 ענו בשם עצמם



איור 8.1: מצב סוציאקונומי לפי הכנסה חודשית של העונים בשם עצמם

75% מכירים את הבעיה במידה רבה עד בינונית, 90% מסכימים שיש צורך לטפל בבעיה, 60% חושבים שמערכת כזו חשובה ביותר, 95% היו רוכשים את המוצר לביתם, רוב העונים כתבו שהיו מוכנים לשלם דמי שכירות חודשיים של 200 ₪ אך היו שכתבו שהיו מוכנים לשלם גם 1000 ₪ ואף אחד העונים כתב "לנוחות אין מחיר, אם זה עוזר כמה שיעלה".

### 8.1.2. ענו בשם בן משפחה



איור 8.2: מצב סוציאקונומי לפי הכנסה חודשית של העונים בשם בן משפחה

100% מסכימים שיש צורך לטפל בבעיה, 88% חושבים שמערכת כזו חשובה ביותר, 100% היו רוכשים את המוצר לביתם, רוב העונים כתבו שהיו מוכנים לשלם דמי שכירות חודשיים של 100.

תוצאות הסקר מציגות תמונה ברורה לגבי העובדה שתופעת הנפילות מוכרת בקרב הקשישים, ושגם הם וגם בני משפחתם יהיו מוכנים לרכוש מוצר זה על מנת לשמור על בריאותם.

## 9. סיכום

פרויקט זה עסק בפיתוח אלגוריתם אשר יזהה התדרדרות בשיווי המשקל אצל קשישים, באמצעות מערכת חישה שתקלוט נתונים ותנתח אותם למען הערכת מצב הנבדק, כך שיהיה ניתן לשפר את אורח חייהם של הקשישים. לאחר סקר ספרות מעמיק, נעשה זיהוי של הסיכונים השונים העלולים להאריך ולפגוע בהתקדמות הפרויקט וניתוח חלופות קיימות אפשריות, הוחלט להשתמש במוצר מסוג מערכת חישה מבוססת חיישן LiDAR תלת-ממדי של חברת Leishen Intelligence System. זהו חיישן הבנוי מ-16 זוגות של מקריני לייזר ומקלטים במישורים שונים. היתרונות הבולטים של חיישן זה הם אי פגיעה בפרטיות המשתמש, יכולת לסווג אובייקטים תלת-ממדיים שונים תוך קבלת תוצאות מדויקות ועקביות ובטיחות בשימוש בעיניים חשופות (ללא מכשירים אופטיים מתקדמים). במהלך הפרויקט עלו בעיות תכן שונות, אשר נפתרו לאחר עבודה רבה וחשובים נוספים. תכן המערכת הסופי מכיל את מערכת החישה הכוללת את חיישן ה-LiDAR ומעמד לחיישן, ובנוסף, האלגוריתם למדידת מהפרמטרים החשובים לניטור וזיהוי סיכונים אצל קשישים, אשר ניתן ונדרש עוד לפתח אותו לרמות מתקדמות יותר. על מנת לתקף את האלגוריתם שנכתב בוצעו מספר ניסויים כגון; מדידת המרחק האוקלידי אותו עובר הנבדק בהשוואה למרחק שנכתב שהוא מבצע על פי החיישן, סדרת ניסויים במעבדה של פרופסור איציק מלצר במחלקה לפיזיותרפיה, באמצעות מערכת ה-Vicon המתקדמת ומערכת ה-BaMPer, על מנת לוודא שניתן לזהות נפילות וכמעט נפילות על ידי מיקום מרכז המסה בציר האנכי כתלות בזמן. והשוואה בין המדידות שהתקבלו במערכת ה-Vicon לבין המדידות שהתקבלו ב-LiDAR לשם תיקוף האלגוריתם. תוצאות ניסויים אלו הניבו מידע רב אודות האלגוריתם ויעילותו, בעיקר אימתו את קיום הקשר בין מרכז המסה בציר Z לנפילות וכמעט נפילות.

המסקנות העיקריות שעלו מהניסויים הן שהחיישן אכן מזהה תנועה חריגה של הנבדקים כאשר תנועה זו קורית מפרטורבציה של הBaMPer וגורמת ל"כמעט נפילה" של הנבדק. החריגות אצל רוב הנבדקים התרחשו באותן שניות לערך ובהשוואה לפרוטוקול הניסוי, אשר בו מצוין באיזו שנייה אירעה פרטורבציה במערכת, ניתן לראות כי החריגות אכן התרחשו בזמנים בהם אירעה פרטורבציה שגרמה למעידה של הנבדק. על סמך ניתוח תוצאות הניסויים התקבל כי למערכת ה-LiDAR יש דיוק של 50% בהשוואה למערכת ה-Vicon. מספר רעיונות שעלו כדי לשפר את הדיוק הם: עריכת ניסויים נוספים, שינוי של הפרמטרים שהוגדרו עבור אלגוריתם זיהוי הולכי הרגל, שימוש בחיישן LiDAR בעל רזולוציה גבוהה יותר, או בחיישן ה-LiDAR עליו כבר נעשתה אופטימיזציה של הפרמטרים באלגוריתם של Kenji Koide, העושה שימוש בחיישן Velodyne HDL-32e, ופיתוח אלגוריתם ייעודי לפרויקט זה אשר מזהה אנשים, כך שיתאים לחיישן ה-LiDAR בו נעשה שימוש בצורה אופטימלית, בדומה לאלגוריתם זיהוי הולכי הרגל של Kenji Koide.

בפן הכלכלי, על מנת לקבל תמונה רחבה יותר לדרישת המוצר נערך סקר צרכנים לגבי הצורך במוצר, האם תהיה מוכנות לשלם עבור מוצר זה וכמה. הסקר נענה על ידי קשישים אשר גרים בדוור מוגן ונשאלו האם ירכשו את המוצר לעצמם, וגם על ידי בני משפחה של קשישים שנשאלו האם היו רוכשים את המוצר קרוביהם. תוצאות הסקר הציגו תמונה ברורה לגבי העובדה שתופעת הנפילות מוכרת בקרב הקשישים, ושגם הם וגם בני משפחתם יהיו מוכנים לרכוש מוצר זה על מנת לשמור על בריאותם.

## **9.1. תכנית להמשך הפרויקט**

פרק זה ידון באפשרויות העתידיות לקידום והמשך הפרויקט.

### **9.1.1 שימוש בבינה מלאכותית לזיהוי כמעט נפילות ונפילות**

על מנת לעשות שימוש ברשת עצבית מלאכותית לצורך זיהוי כמעט נפילות עם חיישן ה-LiDAR, נערכו מספר ניסויים במעבדה לפיזיותרפיה של פרופסור איציק מלצר כפי שמתואר בפרק 7. הניסויים אוחדו לכדי ניסוי אחד ארוך. את הנתונים הרלוונטיים ניתן לראות באיור 9.1 המציג את טבלת הנתונים כ-DataFrame ומקורם. לצורך הסיווג הוגדרה עמודה בינארית של כמעט נפילה כאשר הערכים בעמודה זו הוזנו באופן ידני; כאשר זוהתה כמעט נפילה במציאות, היה ניתן לראות קפיצה בגרפי המיקום והמהירות בפרק זמן מסויים ובפרק זמן זה הערכים בעמודה של 'almost\_fall' הוזנה באופן ידני ל-1.

```
url = 'https://raw.githubusercontent.com/GilSasson/KeepMoving/main/lidar_test.csv'
df = pd.read_csv(url, parse_dates=['time'], index_col='time')
```

```
df.head()
```


	distance_z	velocity_z	dist_from_lidar	almost_fall
time				
2.886151	2.405723	-1.084957	3.5	0
3.023319	2.398088	-0.545561	3.5	0
3.114092	2.393277	-0.379287	3.5	0
3.188361	2.383059	-1.503750	3.5	0
3.319973	2.375078	-0.806650	3.5	0

```
df.tail()
```

	distance_z	velocity_z	dist_from_lidar	almost_fall
time				
1264.591417	1.259751	0.085940	3.5	0
1264.689163	1.260624	0.145224	3.5	0
1264.786910	1.261609	0.096537	3.5	0
1264.884656	1.263149	0.090116	3.5	0
1264.982402	1.263741	0.043488	3.5	0

## איור 9.1: טבלת הנתונים כ- DataFrame ומקורם

באיור 9.2 ניתן לראות גרף הממחיש את הזמנים בהם התרחשה "כמעט נפילה".



## איור 9.2: הזמנים בהם התרחשה "כמעט נפילה"

למימוש הפרויקט אנו ממליצים לעשות שימוש במודל LSTM כפי שמוצג ב- [29] ו- [30], לאחר קריאת הנתונים, יש לחלק את הנתונים למערכים של אימון (train) ובדיקה (test) כפי שמוצג באיור 9.3 כאשר מערך האימון משמש ללמידה כדי להתאים את הפרמטרים השונים כגון המשקלים. בניסוי זה הוחלט לחלק כמות שווה של נתונים עבור שני המערכים. ככל שיש יותר נתונים ניתן להקצות יותר אחוזים עבור מערך האימון שכן אחוז קטן מכמות גדולה של נתונים עדיין מספקת הרבה מידע לבדיקה.

```
train_size = int(len(df) * 0.5)
test_size = len(df) - train_size
train, test = df.iloc[0:train_size], df.iloc[train_size:len(df)]
print(len(train), len(test))
```

### איור 9.3: חילוק הנתונים ל-train ו-test

יש צורך לעבד את הנתונים (נורמליזציה) לפני ה- Gradient Descent ולשנות את הערכים בעמודות השונות במערך הנתונים הנתון לקנה מידה משותף מבלי לעוות הבדלים בטווחי הערכים או לאבד מידע. באיור 9.4 ניתן לראות נורמליזציה על ידי Robust Scaler אשר מסיר את החציון ומנרמל את הנתונים על פי שיטת טווח בין-רבעוני (IQR).

```
from sklearn.preprocessing import RobustScaler
pd.options.mode.chained_assignment = None

f_columns = ['distance_z', 'velocity_z', 'dist_from_lidar']

f_transformer = RobustScaler()
almost_fall_transformer = RobustScaler()

f_transformer = f_transformer.fit(train[f_columns].to_numpy())
almost_fall_transformer = almost_fall_transformer.fit(train[['almost_fall']])

train.loc[:, f_columns] = f_transformer.transform(train[f_columns].to_numpy())
train['almost_fall'] = almost_fall_transformer.transform(train[['almost_fall']])

test.loc[:, f_columns] = f_transformer.transform(test[f_columns].to_numpy())
test['almost_fall'] = almost_fall_transformer.transform(test[['almost_fall']])
```

### איור 9.4: נורמליזציה על ידי Robust Scaler

יש צורך להמיר את הנתונים לפורמט של סדרת זמן ולשים לב שהלמידה מתבצעת אך ורק על הנתונים של המיקום, המהירות ומרחק החיישן ולא מעמודות המטרה הבינארית, כפי שמוצג באיור 9.5.

```
def create_dataset(X, y, time_steps=1):
    Xs, ys = [], []
    for i in range(len(X) - time_steps):
        v = X.iloc[i:(i + time_steps)].values
        Xs.append(v)
        ys.append(y.iloc[i + time_steps])
    return np.array(Xs), np.array(ys)
```

```
time_steps = 5
f_columns = ['distance_z', 'velocity_z', 'dist_from_lidar']
train_c = train[f_columns]
test_c = test[f_columns]

X_train, y_train = create_dataset(train_c, train.almost_fall, time_steps)
X_test, y_test = create_dataset(test_c, test.almost_fall, time_steps)
```

### איור 9.5: המרת הנתונים לפורמט של סדרת זמן

לאחר מכן יש להגדיר את המודל של הרשת באופן דומה המוצג באיור 9.6.

```
model = keras.Sequential()
model.add(
    keras.layers.Bidirectional(
        keras.layers.LSTM(
            units=128,
            input_shape=(X_train.shape[1], X_train.shape[2])
        )
    )
)
model.add(keras.layers.Dropout(rate=0.3))
model.add(keras.layers.Dense(units=1))
model.compile(loss='mean_squared_error', optimizer='adam')
```


### איור 9.6: הגדרת מודל רשת ה-LSTM

באיור 9.7 ניתן לראות אימון של המודל על הנתונים.

```
history = model.fit(
    X_train, y_train,
    epochs=100,
    batch_size=16,
    validation_split=0.1,
    shuffle=False
)
```

### איור 9.7: אימון של המודל על הנתונים

ניתן להשתמש בעקומת למידה כדי לאבחן את התנהגות המודל. התאמה טובה מזוהה על ידי ירידה בגרף האימון והבדיקה עד לנקודה יציבה ועם פער מינימלי בין העקומות. באיור 9.8 ניתן לראות את עקומת הלמידה שהתקבלה מנתוני הניסויים.



איור 9.8: עקומת הלמידה שהתקבלה מנתוני הניסויים

כעת ניתן ליצור מודל ולהתאים אותו לנתונים המאומנים ולהשתמש בהם כדי לבצע חיזוי כמתואר באיור 9.9.


```
y_pred = model.predict(X_test)

y_test_inv = almost_fall_transformer.inverse_transform(y_test.reshape(1,-1))
y_train_inv = almost_fall_transformer.inverse_transform(y_train.reshape(1,-1))
y_pred_inv = almost_fall_transformer.inverse_transform(y_pred)
```

איור 9.9: יצירת מודל החיזוי

באיור 9.10 ניתן לראות המחשה גרפית של מודל החיזוי.





איור 9.10: המחשה גרפית של מודל החיזוי

כפי שניתן לראות באיור 9.10, המודל מצליח לחזות את הכמעט נפילות באופן די טוב. יש לשים לב כי בגלל שה"כמעט נפילה" מתרחשת בפרק זמן מסוים, המודל מסווג בפרק זמן זה מספר רב של כמעט נפילות. מכיוון שיש עניין במספר הכמעט נפילות אשר התרחשו ולא דווקא מתי הן התרחשו, יש צורך לכמת כל כמעט נפילה לפרק זמן מסוים או לפי מספר הדגימות העוקבות. בעתיד, יש צורך לאסוף נתונים נוספים בניסוי כמעט נפילה כאשר ה-LiDAR ממוקם במרחקים שונים (בניסויים שנערכו עד כה, ה-LiDAR נמצא במרחק קבוע של 3.5 מטרים מהנבדק). כאמור, אם ניתן לזהות כמעט נפילות בשיטה זו אז כנראה שגם יהיה ניתן לזהות נפילות על ידי אימון נתונים מניסויי נפילה. ההבדל היחיד בין הניסויים הינו שלאחר הנפילה מרכז המסה של הנבדק לא חוזר למקומו ושמהירותו מתאפסת. לכן, יכול להיות מצב שהמודל לזיהוי כמעט נפילה יסווג נפילה אמיתית בתור כמעט נפילה. בכדי לדעת האם מדובר בנפילה אמיתית, אפשר ללכת על פי ההיגיון הבא:

```
#Logic example to count number of falls
velocity = [3, 3, 3, 3, 3, 4, ..., 2, 1, 0, 0, 0, 0] # velocity of a person walking and then falling
almost_fall_count=0
fall_count=0
for j in range(len(y_pred_inv)): #range(0, num of samples)
    for i in range(0,200): # last 200 samples (i.e [-i:])
        if y_pred_inv[-i:][0] > 0.9 and y_pred_inv[i][0] < 1.1: # if classified almost_fall
            almost_fall_count = almost_fall_count+1
        if almost_fall_count > 0 and velocity[j+200] == 0:
            fall_count = fall_count+1
            almost_fall_count = 0 # resetting if condition
```

איור 9.11: דוגמא לוגית ליישום חיזוי נפילות באמצעות "כמעט נפילות"

להמשך פרויקט זה, אנו מציעים לאסוף נתונים נוספים, כלומר, לבצע את הניסויים שבוצעו עד כה עם חיישן הליידר אך ממרחקים שונים בין החיישן לנבדק. מנתונים אלו ניתן להוסיף נתונים סינתטיים חדשים על ידי

הפיכה של הנתונים, סיבוב ציקלי, רעש גאוסי נמוך ועוד [40]. לאחר אימון סופי ומיקסוס דיוק המודל, יהיה ניתן ליישם מודל זה ולסווג כמעט נפילות ואף נפילות בזמן אמת.

### 9.1.2 דוח מעקב חודשי

כפי שצוין בפרק 6.5, כחלק מניטור נתוני המשתמש בנוגע ליציבותו, ויכולת המכשיר לסווג נפילות וכמעט נפילות ולבצע ניתוח ותרגום נתונים אלה לשם הערכת מצבו של המשתמש, יש לפתח את האפשרות להדפיס פלט נתונים למשתמש כדוח מעקב חודשי אשר יציג את התנהלותו של המשתמש במהלך החודש האחרון בביתו; מספר הפעמים בהן נפל או מעד, הזמן בו הוא לא זז ביחס לזמן בו הוא היה נמצא בביתו. דוח זה יאפשר למשתמש ולמשפחתו לפקח על מצבו הבריאותי ותפקודו, כך שיוכלו לנסות לערב בזמן גורמים קליניים מתאימים שיעזרו בשיפור אורח חיי המשתמש מידת הצורך.

### 9.1.3 קשר עם מוקד חירום

בנוסף לכך שהמכשיר יספק מידע חודשי אודות מצבו של המשתמש, יש לפתח ממשק אשר יחבר אותו למערכת תקשורת אלחוטית כך שברגע שהחיישן מזהה שהמשתמש נופל לגמרי ולא חוזר לעמוד לאחר זמן סביר של שניות, תהיה פקודה בקוד שמובילה לשיחה או התרעה למוקד החירום דרך המחשב המחובר אליו.

### 9.1.4 ממשק משתמש גרפי

יש צורך בפיתוח ממשק משתמש, UI (User Interface), לצורך חוויה מהנה, נוחה וקלה של המשתמש בעת הפעלת המערכת ובעת הפקת הפלט הרצוי בצורה אמינה ונגישה (User Experience, UX). בהמשך הפרויקט, אנחנו מציעים לפתח ממשק משתמש גרפי המבוסס על עיצוב גרפי. לשם כך, יש צורך במהנדס UI/UX ובמעצב גרפי בכדי להתאים את המראה הכללי של הממשק כך שיהיה נעים לעין ואסתטי

פיתוחים אלה לא רחוקים מלהתקיים בדוח הנוכחי, אמנם הם דורשים זמן נוסף ואפילו צוות פיתוח נוסף, על מנת לעבוד עליהם ולפתח אותם ברמה המיטבית והם ללא ספק הכרחיים וחשובים לפיתוחו של המוצר, ולשמירה על חיי המשתמש.

## 10. ניהול סיכונים ותוכנית עבודה

### 10.1. ניתוח סיכונים

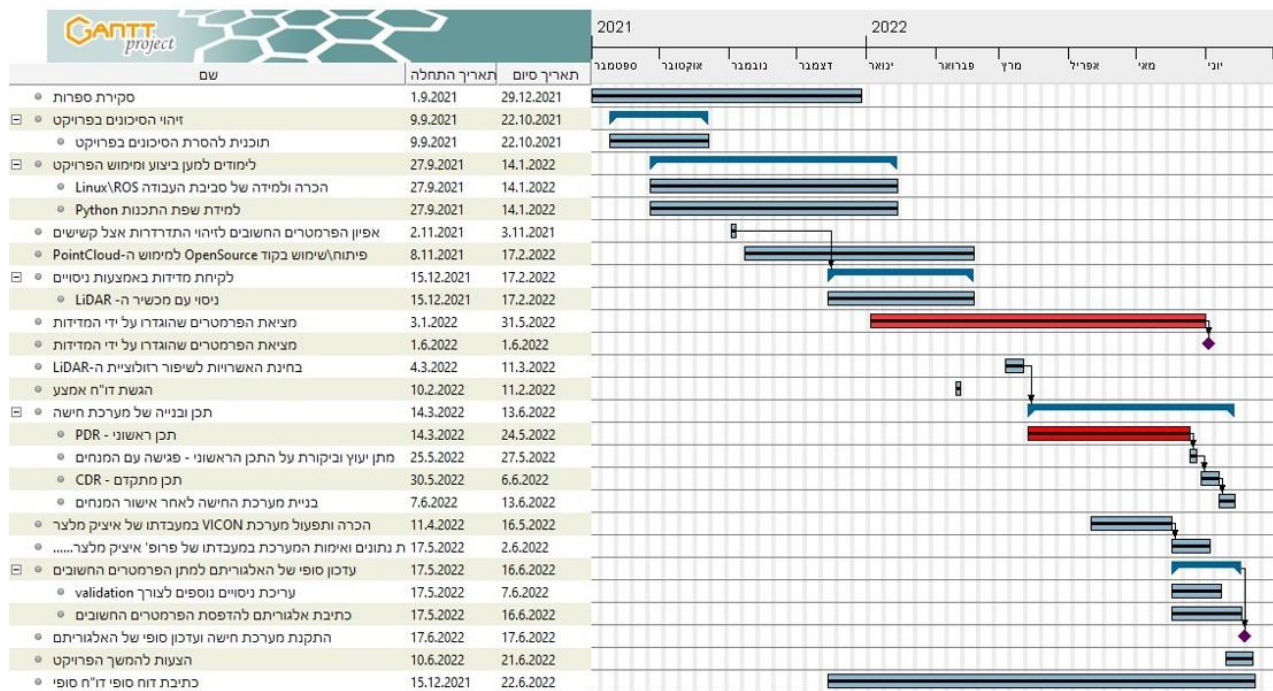
כחלק מביצוע הפרויקט היה צורך להתחשב במספר סיכונים אשר היו גרמו או עלולים לגרום לעיכובים ומכשולים במהלכו. להלן, טבלה 10.1 אשר מפרטת אודות סיכונים אלה:

טבלה 10.1: ניתוח סיכונים

הגדרת הסיכון	רמת סיכון	התמודדות עם הסיכון
רזולוציה נמוכה ולא מספקת לזיהוי חלק מהפרמטרים החשובים לניטור וזיהוי סיכונים אצל קשישים	גבוהה	התייעצות עם המנחים והגעה להבנה כי הפרויקט לא מחייב מדידת פרמטרים כגון גובה הבהונות מעל הרצפה (foot clearance) הדורשים רזולוציה גבוהה מאוד, שכן זיהוי נפילות וכמעט נפילות לא מחייב פרמטר זה וניתן לבצע ניטור ולזהות סיכונים גם על בעזרת פרמטרים אחרים
למידת סביבת העבודה, ubuntu ו- ROS	קלה	למידה עצמאית ממקורות אמינים וליווי מקצועי על ידי סטודנטים לתואר שני ושלישי בהנדסת מכונות במעבדתו של פרופ' אמיר שפירא
חיישן ה- Leishen Intelligence Systems' C16 LiDAR במיוחד. שבר ואובדן תקל בחיישן זה עלולים להאריך את משך הפרויקט באופן משמעותי	גבוהה	עבודה עם מכשיר זה נעשית בקפדנות ובעדינות רבה בכדי למנוע מקרים של שבר או תקלה כתוצאה מלכלוך, התחממות יתר ונפילות
למידת שפת תכנות Python	קלה	למידה עצמאית ומקורס בחירה "יישומים של בינה מלאכותית וקריית מידע להנדסה"
למידה ויישום של בינה מלאכותית	בינונית	התייעצות עם מומחים בתחום של בינה מלאכותית, למידה מקורס בחירה "יישומים של בינה מלאכותית וקריית מידע להנדסה" ומאתרים מפורסמים כגון StackOverflow ו- Kaggle
למידת מערכת ה- VICON שבמעבדתו של פרופ' איציק מלצר בפקולטה למדעי הבריאות	קלה	ליווי מקצועי והדרכה על ידי פרופ' איציק מלצר וממהנדס המעבדה
עלייה דרסטית בתחלואת וירוס הקורונה	בינונית	התחסנות נגד נגיף הקורונה ועטית מסיכה בקמפוס ובמעבדות

### 10.2. תוכנית עבודה בפועל

באזור 10.1 תוצג תוכנית העבודה באמצעות גאנט.



איור 10.1: גאנט הפרויקט

- [1] World Report on Ageing and Health. World Health Organisation, Geneva(2015) .
- [2] Majumder, S., et al.: Smart homes for elderly healthcare—recent advances and research challenges. *Sensors* 17(11), 2496.(2017)
- [3] Francis-Coad J, Etherton-Beer C, Burton E, Naseri C, Hill AM. Effectiveness of complex falls prevention interventions in residential aged care settings: a systematic review. *JBIC Database System Rev Implement Rep*. 2018 Apr; 16(4): 973-1002.
- [4] Sargent OJ, Dadalco OI, Pickett KA, Travers BG. Balance and the brain: A review of structural brain correlates of postural balance and balance training in humans. *Gait Posture* [Internet]. 2019; 71(November 2018): 245–52.
- [5] בן יצחק ר', "מהי הפרעת הליכה ומה הגורמים לה?".  
<https://healthyaging.co.il/%D7%94%D7%A4%D7%A8%D7%A2%D7%95%D7%AA>.
- [6] קימאיגרום ש', שבי ע', לבנקרון ש', "הערכת מצב התזונה בקרב דיירי מוסד לגריאטריה". חוברת 1, אוקטובר 2007.
- [7] אלבוים גביזון מ', היל ק', לוינגר פ', "גורמי סיכון ודרכי טיפול למניעת נפילות בקרב מטופלים עם דלקות פרקים במפרקי גפה תחתונה". 2013 ; פיזיותרפיה 14 : 16-24.
- [8] Bodanese, E., Ma, Z., Bigham, J., et al.: Device-free daily life (ADL) recognition for smart home healthcare using a low-cost (2D) lidar. In: 2018 IEEE Global Communications Conference (GLOBECOM).(2018)
- [9] Osoba MY, Rao AK, Agrawal SK, Lalwani AK. Balance and gait in the elderly: A contemporary review. *Laryngoscope Investig Otolaryngol*. 2019; 4(1): 143–53.
- [10] Uddin, M.Z., Khaksar, W., Torresen, J.: Ambient sensors for elderly care and independent living: a survey. *Sensors* 18(7), 2027.(2018)
- [11] Wikipedia, Robot Operating System, [https://en.wikipedia.org/wiki/Robot\\_Operating\\_System](https://en.wikipedia.org/wiki/Robot_Operating_System). Retrieved 3 January 2022.
- [12] ROS.org, Client Libraries, <http://wiki.ros.org/Client%20Libraries>. Retrieved 3 January 2022.
- [13] ROS.org, Packages, <http://wiki.ros.org/Packages>. Retrieved 3 January 2022.
- [14] ROS.org, Rviz, <http://wiki.ros.org/rviz>. Retrieved 3 January 2022.
- [15] National Oceanic and Atmospheric Administration (26 February 2021). "What is LIDAR". [oceanservice.noaa.gov](https://oceanservice.noaa.gov). US Department of Commerce. Retrieved 3 January 2022.

- [16] "Adoption of gallium-based lidar sensors gathers pace". [www.argusmedia.com](http://www.argusmedia.com). 2021-06-29. Retrieved 22 April 2022.
- [17] Operation Instruction of C16 Series Multi-line Hybrid Solid-State Lidar, [www.leishen-lidar.com](http://www.leishen-lidar.com).
- [18] IEC 60825-1:2014 Safety of laser products - Part 1: Equipment classification and requirements (in English, French, and Spanish) (3rd ed.). International Electrotechnical Commission. 2014-05-15. p. 220. - TC 76 - Optical radiation safety and laser equipment.
- [19] Guerrero-Higueras, Á.M., et al.: Tracking people in a mobile robot from 2D LIDAR scans using full convolutional neural networks for security in cluttered environments. *Front. Neurobotics* 12, 85.(2019)
- [20] Bailey, Ken (1994). "Numerical Taxonomy and Cluster Analysis". *Typologies and Taxonomies*. p. 34. ISBN 9780803952591.
- [21] Kaisa Miettinen (1999). *Nonlinear Multiobjective Optimization*. Springer. ISBN 978-0-7923-8278-2. Retrieved 29 May 2022 .
- [22] Michael Nielsen, *Neural Networks and Deep Learning*, 2019.
- [23] Courant, Richard (January 1943). "Variational methods for the solution of problems of equilibrium and vibrations".
- [24] "Balance recovery stepping responses during walking were not affected by a concurrent cognitive task among older adults"; Inbal Paran, Hadas Nachmani, Moti Salti, Ilan Shelef and Itshak Melzer.
- [25] <https://www.Vicon.com>. Retrieved 6 June 2022.
- [26] <http://aranne5.bgu.ac.il/others/BalshaiHagai.pdf>. Retrieved 6 June 2022.
- [27] Kenji Koide, Jun Miura, and Emanuele Menegatti, *A Portable 3D LIDAR-based System for Long-term and Wide-area People Behavior Measurement*, *Advanced Robotic Systems*, 2019.
- [28] <https://www.ncbi.nlm.nih.gov/books/NBK235613>. Retrieved 6 June 2022.
- [29] <https://medium.com/@nutanbhogendrasharma/tensorflow-demand-prediction-with-london-bike-sharing-dataset-3436ac12f230> . Retrieved 6 June 2022.
- [30] [https://github.com/shakibyzn/London-bike-sharing-time-series-analysis/blob/master/bike\\_sharing\\_analysis\\_using\\_lstm\\_model.ipynb](https://github.com/shakibyzn/London-bike-sharing-time-series-analysis/blob/master/bike_sharing_analysis_using_lstm_model.ipynb). Retrieved 6 June 2022.

- [31] Haselich. M, Jobgen. B, Wojke. N, Hedrich. J, Paulus. D, Confidence-Based Pedestrian Tracking in Unstructured Environments Using 3D Laser Distance Measurement, IEE/RSJ International Conference on Intelligent Robots and Systems, 2014
- [32] .A.Doucet, N. de Freitas, K. Murphy, and S. Russell. RaoBlackwellised Particle Filtering for Dynamic Bayesian Networks. In Proceedings of the Sixteenth Conference Annual Conference on Uncertainty in Artificial Intelligence, pages 176–183, 2000.
- [33] K. Kidono, T. Miyasaka, A. Watanabe, T. Naito, and J. Miura. Pedestrian recognition using high-definition LIDAR. In Proceedings of the IEEE Intelligent Vehicles Symposium, pages 405–410, 2011.
- [34] ניתוח מרכיבים ראשיים (PCA) נסיכת המדעים - יוסי לוי, איך ואיך לא - <http://www.sci-princess.info/archives/2086>.
- [35] Andreas Müller (2012). Kernel Approximations for Efficient SVMs (and other feature extraction methods).
- [36] L. Navarro-Serment, C. Mertz, and M. Hebert. Pedestrian Detection and Tracking Using Three-dimensional LADAR Data. International Journal of Robotics Research, Special Issue: Seventh International Conference on Field and Service Robots, 29(12): 1516–1528, 2010.
- [37] V. N. Vapnik, A. Ya. Lerner, “Recognition of Patterns with help of Generalized Portraits”, Avtomat. i Telemekh., 24: 6 (1963), 774–780, [www.mathnet.ru](http://www.mathnet.ru).
- [38] ROS.org, Display Types, Axes. <http://wiki.ros.org/rviz/DisplayTypes/Axes> Retrieved 31 January 2022.
- [39] Gradient Descent, [https://he.wikipedia.org/wiki/Gradient\\_descent](https://he.wikipedia.org/wiki/Gradient_descent). Retrieved at 14 June, 2022.
- [40] Shorten, Connor; Khoshgoftaar, Taghi M. (2019). "A survey on Image Data Augmentation for Deep Learning".
- [41] Interquartile range, [https://en.wikipedia.org/wiki/Interquartile\\_range](https://en.wikipedia.org/wiki/Interquartile_range). Retrieved at 21 June 2022.

### 12.1. טכניקת ניתוח האשכולות של Häselich

בעבודתו של Häselich ועמיתיו [31] פותחה שיטה שמטרתה זיהוי ומעקב מדויק של הולכי רגל ללא מעקב אחרי False Negatives. שיטה זו משלבת בין אלגוריתם זיהוי באמצעות מכונת תמך וקטורי או באנגלית Support-vector machine או SVM לבין אלגוריתם מעקב המבוסס על מסנני חלקיקים ובפרט בטכניקה הידועה בשם Rao-Blackwellisation המגבירה את יעילותו של מסנן החלקיקים, עליו ניתן לקרוא בפירוט ב-[32].

#### 12.1.1. זיהוי הולכי רגל

תת-פרק זה מתאר את גישת הזיהוי של Häselich ועמיתיו ומחולק לארבעה שלבים – הסרת הקרקע, ניתוח אשכולות, חילוף מאפיינים (feature extraction) ושילבי סיווג.

#### 12.1.2. הסרת הקרקע

המטרה של הסרת הקרקע הינה להפריד בין נקודות מכשול לנקודות קרקע, על מנת להפחית בעומס החישובי של האלגוריתם. ראשית, כל נקודות התלת-ממד מחיישן ה-LiDAR (להן אנו קוראים ענן נקודות או באנגלית Point Cloud) "מוקרנות" על ידי אלגוריתם שנקרא Occupancy grid map לרשת דו-ממדית המקבילה לקרקע [33]. מכיוון שלא ניתן להניח כי משטח הקרקע הוא מישורי, בהינתן מדרגות או גבעות באם אזור הסריקה שלנו בחוץ, בגישתם של Häselich ועמיתיו הוחלט להכניס את כל המידע לרשת תלת-ממדית עם רזולוציה של  $0.1 \times 0.1 \times 0.1 \text{ m}^3$  לכל תא. התאים מסודרים על פי גובהם, מהגבוה לנמוך כאשר הגובה של כל תא הינו המרחק בין הנקודה העליונה ביותר לנקודה התחתונה ביותר בתא. כל תא מסווג ביחס לנקודות המכילות אותו וביחס לתאים השכנים שלו. כלומר, לצורך סיווג התאים מבין שלוש קטגוריות (מכשול, רצפה או תא ריק), מתבצע חישוב המרחקים של כל הנקודות הגבוהות והנמוכות ביותר בכל תא.

#### 12.1.2.1. אלגוריתם ניתוח האשכולות

מטרת אלגוריתם ניתוח האשכולות הוא בעצם לקחת את קבוצת התאים שהתקבלה בשלב הקודם ולקבץ אותם לקבוצות שונות. מצד אחד יש צורך בקיבוץ התאים שסווגו 'מכשול' כמועמדים להולכי רגל, ומצד שני לפצל קבוצות גדולות של נקודות במרחב, על מנת לעשות הפרדה בין מכשול להולך רגל הקרובים זה לזה.



### 12.1.2.2. חילוף מאפיינים

בכדי להעריך את המאפיינים של ה-clusters השונים, Häselich ועמיתיו בחרו לעשות שימוש בניתוח גורמים ראשיים או באנגלית Principal Component Analysis (PCA) שהיא שיטה להתמרה ליניארית של נתונים למערכת קואורדינטות חדשה, שבה המידע בקואורדינטות השונות הוא אורתוגונלי ובעל שונות הולכת וקטנה, כלומר תהליך הורדת הממד נעשית על ידי לקיחת מספר קטן של גורמים ראשיים בלבד, שהשונות שלהם היא הגדולה ביותר. [34] ובווקטור המאפיינים הבא:

$$\mathbf{f} = (f_1, f_2, \dots, f_8) \quad (12.1)$$

כאשר המאפיינים  $f_1$  עד  $f_8$  מייצגים, בהתאמה, את מספר הנקודות באשכול, המרחק המינימלי בין האשכול לחיישן, מטריצת השונות המשותפת התלת ממדית של האשכול, טנזור מומנט ההתמד מנורמל, מטריצת השונות הדו-ממדית באזורים שונים, היסטוגרמה דו-ממדית מנורמלת של המישור הראשי והמשני עליהם ניתן לקרוא בהרחבה במאמרו של Navarro Serment ועמיתיו [24], ומאפיין אחד נוסף שנועד להבדיל בין הולכי רגל לעמודים ואו עצים. להלן מטריצת השונות המשותפת  $\Sigma \in R^{3 \times 3}$  [14]

$$\Sigma = \frac{1}{n-1} \sum (\mathbf{x}_k - \mathbf{m})(\mathbf{x}_k - \mathbf{m})^T \quad (12.2)$$

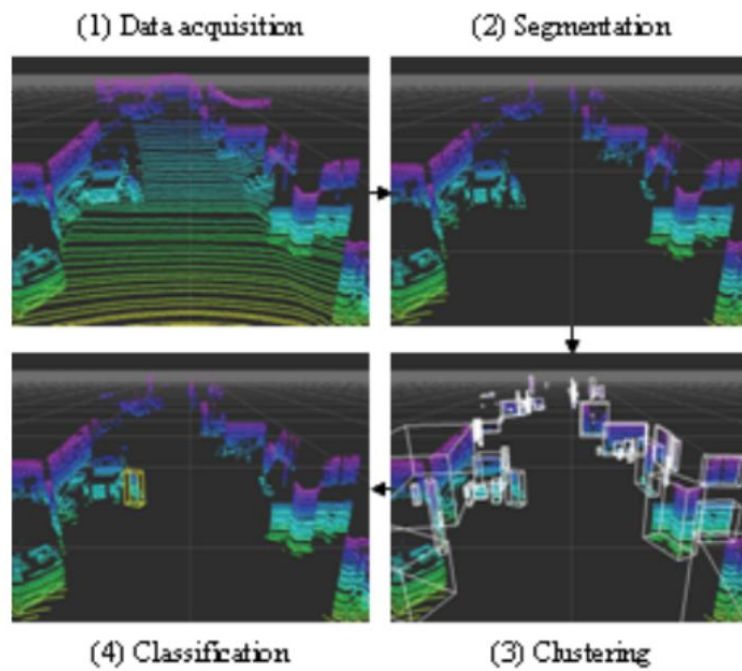
כאשר  $S_k = \{\mathbf{x}_{1k}, \mathbf{x}_{2k}, \dots, \mathbf{x}_{nk}\}$  הן הנקודות השייכות לאובייקט  $k$  שרכיביו מיוצגים במערכת צירים קרטזית  $\mathbf{x} = (x, y, z)$ , ו- $\mathbf{m}$  הינו ווקטור הממוצע מכל דגימה. להלן טנזור מומנט ההתמד המנורמל  $\mathbf{M} \in R^{3 \times 3}$  [14]

$$\mathbf{M} = \begin{bmatrix} \sum_{k=1}^n (y_k^2 + z_k^2) & -\sum_{k=1}^n x_k y_k & -\sum_{k=1}^n x_k z_k \\ -\sum_{k=1}^n x_k y_k & \sum_{k=1}^n (x_k^2 + z_k^2) & -\sum_{k=1}^n y_k z_k \\ -\sum_{k=1}^n x_k z_k & -\sum_{k=1}^n y_k z_k & \sum_{k=1}^n (x_k^2 + y_k^2) \end{bmatrix} \quad (12.3)$$

מניתוח גורמים ראשיים (PCA) מתקבלים שלושה ווקטורים עצמיים  $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$  ושלושה ערכים עצמיים בהתאמה  $\lambda_1 > \lambda_2 > \lambda_3$ . כלומר בתהליך הורדת הממד המישור הראשי מורכב מהווקטורים  $\mathbf{e}_1$  ו- $\mathbf{e}_2$  שהם המרכיבים הגדולים ביותר והמישור המשני מורכב מהווקטורים  $\mathbf{e}_1$  ו- $\mathbf{e}_3$ , כאשר בגישתו של Navarro לזיהוי הולכי רגל מניחים כי הולך הרגל הוא בעמידה או בישיבה כאשר גבו זקוף (Upright position) ולכן מצפים שהווקטור  $\mathbf{e}_1$  יהיה מיושר אנכית עם גופו של הולך הרגל.

### 12.1.2.3. שלב הסיווג

בשלב זה מתבצע סיווג בינארי בין 'הולך רגלי' (1) ו- 'לא הולך רגלי' (0). Häselich ועמיתיו בחרו להשתמש ב-SVM עם פונקציית Radial basis function kernel (rbf-kernel) [35], כפי שהוצע במאמר [33] ביחד עם ווקטור המאפיינים  $f$  שתואר בתת פרק חילוף המאפיינים. באיור 12.1 ניתן לראות תיאור ויזואלי לתהליך זיהוי הולכי הרגל כפי שהוצע במאמר של Kidono ועמיתיו.




איור 12.1: תהליך זיהוי הולכי הרגל של Kidono ועמיתיו

## 12.2. מידות למתקן מערכת החישה

בנספח זה יוצגו מידות למתקן מערכת החישה אשר הוצג בפרק 5.1.

באיור 12.2 ניתן לראות את מידות החלק העליון, עליו יושב חיישן הLiDAR.



איור 12.2: מידות החלק העליון

Technical drawing of a Lidar Mount (Part 2) showing three views: Front View, Side View, and Isometric View.

**Front View:** A square plate with a central circular hole. The overall width is 210.00 mm. The hole has a diameter of  $\phi 103.00$  mm. The distance from the left edge to the center of the hole is 77.94 mm. The distance from the bottom edge to the center of the hole is 43.87 mm. There are four mounting holes, each with a diameter of  $\phi 6.15 \times 4$ .

**Side View:** A rectangular plate with a width of 100.00 mm and a height of 150.00 mm.

**Isometric View:** Shows the 3D shape of the Lidar Mount, including the central circular hole and the four mounting holes.

**Dimensions:**

- Overall Width: 210.00 mm
- Overall Height: 150.00 mm
- Central Hole Diameter:  $\phi 103.00$  mm
- Distance from Left Edge to Center: 77.94 mm
- Distance from Bottom Edge to Center: 43.87 mm
- Mounting Hole Diameter:  $\phi 6.15 \times 4$
- Side View Width: 100.00 mm
- Side View Height: 150.00 mm
- Isometric View Dimensions: 12.50 mm, 16.51 mm, 75.00 mm

### איור 12.3: מידות החלק התחתון

### **12.3. קבצי הפרויקט**

בקישור הבא ניתן למצוא ולהוריד את כל תכני פרויקט זה:

<https://github.com/GilSasson/KeepMoving>